

Edital:	Edital PIIC 2025/2026	
Área (CNPq):	Ciência da Computação	
Subárea (CNPq):	Metodologia e Técnicas da Computação	
Título do Projeto:	Pesquisa Operacional e Inovação em Logística Regional	
Título do Subprojeto:	Otimização Dinâmica de Rotas para Coleta de Resíduos Sólidos: Adaptação do Algoritmo de Solomon com Integração IoT	
Orientadora:	Maria Claudia Silva Boeres	
Estudante:	Emilly Lopes Das Neves	

Comparação rigorosa de cinco heurísticas clássicas para o VRPTW, com aplicação à coleta de resíduos sólidos via Digital Twin

Resumo. Este trabalho realiza uma comparação científica, justa e reproduzível de cinco heurísticas e meta-heurísticas clássicas para o Problema de Roteamento de Veículos com Janelas de Tempo (VRPTW): a heurística de inserção I1 de Solomon (1987), a Descida em Vizinhança Variável (VND) (Hansen and Mladenović, 2001), o GRASP (Feo and Resende, 1995) nas formas fixa e reativa (Prais and Ribeiro, 2000), e a Busca Tabu (Glover, 1989). Todos os métodos compartilham o mesmo núcleo (leitor de instâncias, função de distância, avaliador de viabilidade, conjunto de vizinhanças e gerador pseudoaleatório), de modo que as diferenças observadas decorram exclusivamente da estratégia de busca. A função-objetivo otimizada é a distância total sob a convenção do 12º Desafio DIMACS; a contagem de veículos é reportada como medida secundária. Avaliamos as 56 instâncias de 100 clientes de Solomon, com calibração de parâmetros por *irace* (López-Ibáñez et al., 2016) sob divisão treino/teste, parada por número de iterações sem melhoria, e comparação estatística por Friedman seguida do pós-teste de Nemenyi (Demšar, 2006). A viabilidade (cobertura de todos os clientes, capacidade e janelas de tempo) é garantida por construção e *reverificada de forma independente* em todas as soluções. Por fim, um *Digital Twin* aplica os algoritmos calibrados a um cenário de coleta de resíduos com localizações reais de Vitória/ES, como prova de conceito.

Palavras-chave: VRPTW; meta-heurísticas; GRASP; Busca Tabu; comparação experimental; coleta de resíduos.

1 Introdução

A gestão de resíduos sólidos urbanos impõe desafios operacionais, econômicos e ambientais aos municípios. Sistemas convencionais de coleta, baseados em rotas fixas e frequências predeterminadas, geram deslocamentos desnecessários e respondem mal a situações de enchimento crítico dos recipientes (Pardini et al., 2020; Lozano et al., 2018). A literatura aponta que integrar monitoramento em tempo real e otimização de rotas pode tornar a coleta mais eficiente (Lozano et al., 2018; Barth et al., 2023).

Este subprojeto de Iniciação Científica combina sensoriamento IoT via LoRaWAN (Ramson et al., 2021; Almeida and Borin, 2021) com heurísticas baseadas no algoritmo de Solomon (1987) para o VRPTW, além de um *Digital Twin* para simulação e visualização. A pergunta de pesquisa é: *de que modo a comparação criteriosa de heurísticas clássicas para o VRPTW pode fundamentar um planejamento de coleta mais responsivo e eficiente, preservando a factibilidade temporal das rotas?*

A contribuição deste relatório é metodológica e experimental, organizada em três camadas: (i) um **benchmark estático** sobre as instâncias clássicas de Solomon, que estabelece a base de comparação justa e calibra os algoritmos; (ii) uma **análise estatística** do desempenho relativo dos cinco métodos; e (iii) uma **aplicação dinâmica** (Digital Twin) que transfere os algoritmos calibrados a um cenário de coleta de resíduos. Enfatizamos que o *benchmark* estático é a *fundação metodológica* sobre a qual a aplicação dinâmica se apoia: os mesmos operadores e parâmetros validados nas instâncias de Solomon são reaproveitados no Digital Twin.

2 O Problema de Roteamento com Janelas de Tempo

2.1 Formulação

Seja um grafo completo $G = (V, A)$, com $V = \{0, 1, \dots, n\}$, em que o vértice 0 é o depósito e $C = \{1, \dots, n\}$ são os clientes. A cada cliente i associam-se: demanda $q_i \geq 0$, janela de tempo $[e_i, \ell_i]$ e tempo de serviço s_i . O depósito tem janela $[e_0, \ell_0]$ (o horizonte) e $q_0 = s_0 = 0$. Uma frota homogênea de veículos de capacidade Q parte e retorna ao depósito. A cada arco (i, j) associam-se uma distância d_{ij} e um tempo de viagem t_{ij} .

Uma *rota* é uma sequência $r = \langle 0, c_1, \dots, c_m, 0 \rangle$. Definindo o instante de chegada $a_{c_1} = t_{0,c_1}$ e, para $k > 1$, o início de serviço $b_{c_k} = \max(a_{c_k}, e_{c_k})$ com $a_{c_k} = b_{c_{k-1}} + s_{c_{k-1}} + t_{c_{k-1},c_k}$,

a rota é viável se

$$b_{c_k} \leq \ell_{c_k} \quad \forall k, \quad \sum_k q_{c_k} \leq Q, \quad b_{c_m} + s_{c_m} + t_{c_m,0} \leq \ell_0. \quad (1)$$

Uma *solução* S é um conjunto de rotas $\mathcal{R}(S)$ em que cada cliente é visitado **exatamente uma vez**. Suas duas grandezas de interesse são a **distância total** e o **número de veículos**:

$$D(S) = \sum_{r \in \mathcal{R}(S)} \sum_{(i,j) \in r} d_{ij}, \quad K(S) = |\mathcal{R}(S)|. \quad (2)$$

O objetivo primário deste trabalho é minimizar a distância total $D(S)$, conforme detalhado na Seção 2.2.

2.2 Convenção de distância e função-objetivo

Adotamos a convenção do 12º Desafio DIMACS para o VRPTW (DIMACS, 2022): a distância de cada arco é a euclidiana **truncada** a uma casa decimal, $d_{ij} = \lfloor 10 e_{ij} \rfloor / 10$ (com e_{ij} a distância euclidiana), e o tempo de viagem é igual à distância ($t_{ij} = d_{ij}$) — a mesma convenção de arredondamento originalmente proposta por Solomon (1987). As regras do desafio adotam explicitamente a minimização *apenas da distância total* (não a hierarquia veículos→distância): verifica-se que a solução respeita o número máximo de veículos disponíveis, mas não há bônus por usar menos. Essa convenção foi escolhida por ser o padrão internacional moderno do desafio e por ser *verificável*: ela reproduz exatamente os custos das soluções de referência (Seção 4.1). Formalmente, o objetivo otimizado pela busca é

$$\min_{S \text{ viável}} D(S), \quad (3)$$

com a distância relatada a uma casa decimal e o número de veículos $K(S)$ como medida secundária. Essa formulação difere da hierarquia *lexicográfica* clássica de Solomon (1987),

$$\text{lex min}_{S \text{ viável}} (K(S), D(S)), \quad (4)$$

que minimiza *primeiro* o número de veículos e, entre soluções de mesma frota, a distância. Sob a Equação (3), a busca não minimiza o número de veículos diretamente; este é uma consequência da construção e só diminui quando um movimento entre rotas esvazia completamente uma rota. A Seção 4.6 discute, de forma transparente, as implicações dessa escolha sobre a comparação com os melhores valores conhecidos.

2.3 Invariantes de viabilidade

Um requisito central deste trabalho é que **toda** solução produzida — pela construção e por todo algoritmo de melhoria — satisfaça a Equação (1) e a cobertura de clientes. Garantimos isso por três mecanismos redundantes:

1. **Avaliação por rota.** Cada rota mantém os vetores de chegada, início e partida, recalculados a cada modificação; a viabilidade da janela e da capacidade é verificada nessa passagem.
2. **Critério Push Forward.** Para inserções, calcula-se o *folga (slack)* máximo de deslocamento para frente de cada cliente sem violar a própria janela nem as subsequentes; uma inserção só é aceita se o atraso que provoca couber nessa folga. Isso permite testar viabilidade em $O(1)$ por posição candidata (Solomon, 1987).
3. **Verificador independente.** Toda solução final é reavaliada do zero por um verificador que percorre cada rota e checa as quatro restrições — cobertura ($\forall i \in C$ visitado uma vez), capacidade, janelas e retorno ao depósito —, sem reaproveitar nenhuma estrutura da busca. É um *portão* de correção.

A consequência prática (Seção 4.2) é que, em todas as execuções realizadas neste trabalho, **nenhuma** solução inviável foi produzida por qualquer algoritmo — e o pipeline de experimentos trata uma eventual violação como erro fatal, interrompendo o estudo em vez de registrá-la e seguir. O critério de aceitação de *todos* os operadores de melhoria descarta movimentos inviáveis *antes* de aplicá-los (Seção 3.9); a viabilidade é, portanto, um invariante preservado a cada passo.

3 Metodologia

Todos os algoritmos foram implementados em C++20 sobre um núcleo único: um leitor das instâncias de Solomon, a matriz de distâncias truncadas, o avaliador de viabilidade, o conjunto de vizinhanças e um gerador pseudoaleatório com semente registrada. Compartilhar esse núcleo é uma decisão deliberada de **justiça**: como leitor, distância, vizinhanças e geração de números aleatórios são idênticos, qualquer diferença de desempenho decorre apenas da estratégia de busca, e não de detalhes de implementação.

3.1 Arquitetura do solver e fluxo de execução

O sistema é organizado em um *núcleo compartilhado* e módulos de algoritmo. O núcleo contém: (i) o **leitor de instâncias**, que interpreta o formato de Solomon (coordenadas,

demanda, janela, serviço, capacidade); (ii) a **matriz de distâncias**, único ponto onde as distâncias são calculadas, garantindo valores idênticos a todos os métodos — e que admite, no Digital Twin, matrizes *explícitas* de distância e tempo (Seção 5.2); (iii) a estrutura de **rota**, que mantém em cache os instantes de chegada, início e partida e a *folga* Push Forward de cada cliente, recalculados a cada modificação; (iv) o **avaliador**, que computa a distância total (objetivo) e a chave de comparação; (v) o **conjunto de vizinhanças**, com a avaliação de viabilidade de cada movimento candidato; (vi) o **gerador pseudoaleatório**, semeado de forma determinística; (vii) o **critério de parada**; e (viii) o **verificador independente**.

O fluxo de uma execução é o seguinte: (1) o arquivo da instância é lido e (2) a matriz de distâncias é construída; (3) gera-se uma solução inicial — a I1 (Algoritmo 1) para VND e Busca Tabu, ou a construção gulosa-aleatorizada para o GRASP; (4) a busca local/meta-heurística refina a solução, consultando o avaliador e as vizinhanças e aceitando movimentos conforme as “regras do jogo” (Seção 3.9), até o critério de parada (Seção 3.12); (5) a solução final é **revalidada** do zero pelo verificador independente; e (6) os artefatos são gravados: o arquivo `.sol` (rotas), uma linha de CSV (distância, veículos, iterações, tempo, viabilidade), o traço de convergência e, opcionalmente, instantâneos por movimento.

Em torno do solver, um *pipeline* em Python executa, para cada (algoritmo, instância, semente), o binário do solver; agrega as métricas; aplica os testes estatísticos; e gera as figuras. A calibração por *irace* (Seção 3.13) e a re-execução completa do estudo são orquestradas por *scripts* dedicados, de modo que todo o experimento é reproduzível por um único comando. Por fim, o **Digital Twin** (Seção 5) reaproveita o mesmo binário: a cada ciclo, os sensores atualizam o enchimento das lixeiras, as lixeiras críticas tornam-se uma instância VRPTW, o solver (re)planeja as rotas com os parâmetros calibrados, e os resultados são visualizados.

3.2 Detalhes de implementação

Linguagem e construção. O solver é escrito em C++20 e compilado com `g++ -O2`, *sem dependências externas* (sem CMake nem bibliotecas de terceiros); a construção e os 15 testes unitários são geridos por um Makefile. O ferramental experimental é em Python (biblioteca padrão + `numpy`, `pandas`, `matplotlib`, `scipy`, `scikit-posthocs`).

Estruturas de dados. A Instance guarda, para cada nó, as coordenadas (x, y) , a demanda, a janela $[e_i, \ell_i]$ e o serviço, além da capacidade Q . A DistanceMatrix é um vetor plano $n \times n$ (linha-major), preenchido uma única vez com $\lfloor 10 e_{ij} \rfloor / 10$. Cada

Route armazena a sequência de clientes (o depósito é implícito nas pontas) e *vetores em cache* dos instantes de chegada, início e partida e da folga Push Forward, recalculados por `recompute()` em uma passada para frente (tempos) e uma para trás (folgas); guarda também a carga e a distância acumuladas.

Avaliação dos movimentos. Cada operador de vizinhança monta a(s) sequência(s) candidata(s) e as avalia por `evaluate_seq` — uma simulação completa da rota, em tempo proporcional ao seu comprimento, que devolve viabilidade, distância e carga; apenas movimentos *viáveis* (e melhorantes, ou admissíveis na Busca Tabu) são retidos por um rastreador do melhor movimento. As inserções da construção são testadas em $O(1)$ pela folga Push Forward (`eval_insert`). A Busca Tabu mantém um vetor `tabu_until` indexado por cliente: um movimento é tabu se algum cliente que ele toca foi movido há menos de *tenure* iterações, com aspiração pelo melhor global. O critério de parada usa um relógio monotônico apenas como teto de segurança; o contador de iterações sem melhora é o critério primário.

Reprodutibilidade e instrumentação. O gerador pseudoaleatório de cada execução é semeado combinando a semente da execução (inteiro de 1 a R , registrado no CSV) com um *hash* FNV-1a do nome da instância, que descorrelaciona os fluxos aleatórios entre instâncias que compartilham a mesma semente. O FNV-1a é especificado byte a byte, de modo que o mesmo par (instância, semente) produz o mesmo fluxo aleatório em qualquer plataforma — a reprodutibilidade não depende do compilador. A cada execução o solver grava: o arquivo `.sol` (rotas e custo), uma linha de CSV (algoritmo, instância, semente, distância, veículos, tempo, viabilidade e iterações), o traço de convergência (tempo, melhor custo) e, opcionalmente, instantâneos por movimento para as figuras de evolução. O `Validator`, independente, reavalia a solução do zero — o *portão* de correção.

Pipeline experimental. O `runner.py` invoca o binário do solver via `subprocess` para cada (algoritmo, instância, semente), em paralelo (`ThreadPoolExecutor`), consolidando o CSV mestre e aplicando os parâmetros calibrados (`tuned.json`). A calibração usa o *irace* por meio de um `target-runner` que imprime o gap; os módulos de análise computam as agregações, os testes de Friedman/Nemenyi (`scipy + scikit-posthocs`) e as figuras.

Digital Twin. Os sensores geram o enchimento por um processo de Poisson não-homogêneo (`numpy`); a cada ciclo, as lixeiras críticas são escritas como uma instância e roteadas pelo mesmo binário. Para a malha viária real, `road_network.py` obtém as matrizes de distância e tempo pelo serviço *table* do OSRM e a geometria das ruas pela Overpass (cacheadas em JSON), e o solver as recebe pelas opções `--dist-matrix/--time-matrix`.

(Seção 5.2). Esse desenho mantém o *benchmark* euclidiano inalterado: na ausência de matriz de tempo, o tempo de viagem é igual à distância, e os 15 testes permanecem idênticos.

3.3 Construção: heurística de inserção I1 de Solomon

A construção segue a heurística sequencial I1 de Solomon (1987). A I1 não minimiza a Equação (3) diretamente: seu papel é produzir, de forma gulosa e determinística, a solução viável de partida sobre a qual todos os métodos de melhoria operam. Os critérios locais c_1 e c_2 , definidos a seguir, controlam o acréscimo de distância de cada inserção, o que alinha a construção ao objetivo de distância, mas sem garantia de otimalidade. Cada rota é iniciada (*semente*) com o cliente não roteado mais distante do depósito. Em seguida, repetidamente, para cada cliente não roteado u determina-se a melhor posição de inserção segundo o critério de custo c_1 e escolhe-se o cliente que maximiza o critério c_2 ; insere-se o melhor cliente enquanto houver inserção viável e, quando não houver, abre-se uma nova rota. Para uma inserção de u entre vizinhos (i, j) de uma rota,

$$c_{11}(i, u, j) = d_{iu} + d_{uj} - \mu d_{ij}, \quad c_{12}(i, u, j) = b_{ju} - b_j, \quad (5)$$

$$c_1(i, u, j) = \alpha_1 c_{11}(i, u, j) + \alpha_2 c_{12}(i, u, j), \quad c_2(u) = \lambda d_{0u} - \min_{(i,j)} c_1(i, u, j), \quad (6)$$

em que c_{11} é o acréscimo de *distância* da inserção e c_{12} é o *deslocamento temporal* (push-forward) que u provoca no sucessor — b_j é o início de serviço em j antes da inserção e b_{ju} o início após inserir u . Usamos a configuração canônica $\mu = 1$, $\lambda = 2$, $\alpha_1 = 1$, $\alpha_2 = 0$, fixa para todos os métodos (não calibrada). Com $\alpha_2 = 0$ emprega-se a variante *baseada em distância* de Solomon: o termo temporal c_{12} não chega a ser computado, de modo que a implementação usa $c_1(i, u, j) = c_{11}(i, u, j)$ — coerente com o objetivo DIMACS; μ pondera a economia de remover o arco (i, j) e λ a preferência por clientes distantes do depósito. O Algoritmo 1 detalha o procedimento.

Algoritmo 1 Construção por inserção I1 de Solomon (variante de distância)

Entrada: instância; parâmetros $\mu, \lambda, \alpha_1, \alpha_2$

Saída: solução viável S cobrindo todos os clientes

```

1:  $S \leftarrow \emptyset$ ; marque o depósito como roteado
2: enquanto existe cliente não roteado faça
3:    $u^* \leftarrow$  cliente não roteado mais distante do depósito
4:   abra a rota  $r \leftarrow \langle u^* \rangle$ ; marque  $u^*$  como roteado
5:   repita
6:      $best \leftarrow$  nulo;  $c_2^* \leftarrow -\infty$ 
7:     para todo cliente não roteado  $u$  faça
8:       guarde a posição viável de menor  $c_1(\cdot, u, \cdot)$  em  $r$ 
9:       se  $u$  admite inserção viável e  $c_2(u) = \lambda d_{0u} - c_1^{\min}(u) > c_2^*$  então
10:         $c_2^* \leftarrow c_2(u)$ ;  $best \leftarrow (u, \text{sua melhor posição})$ 
11:       fim se
12:     fim para
13:     se  $best \neq$  nulo então
14:       insira  $best$  em  $r$ ; marque o cliente como roteado
15:     fim se
16:   até  $best =$  nulo
17:    $S \leftarrow S \cup \{r\}$ 
18: fim enquanto
19: retorne  $S$ 

```

Leitura passo a passo. A linha 1 parte de uma solução vazia. Cada nova rota nasce de uma *semente* (linha 3): o cliente mais distante do depósito, escolha que ancora a rota em uma região periférica e tende a reduzir o número total de veículos. O laço interno (linhas 6–14) faz crescer a rota corrente: para cada cliente ainda livre, a linha 8 encontra, em $O(1)$ por posição graças à folga Push Forward, a inserção viável mais barata em distância (critério c_1); a linha 10 então elege, entre esses melhores candidatos, aquele de maior c_2 — a maior “economia” de roteá-lo agora, perto do depósito, em vez de adiá-lo. A rota só se fecha (linha 17) quando nenhuma inserção viável resta, e uma nova é aberta. É essa dinâmica gulosa e sequencial que molda a *solução inicial* de todos os métodos: rotas densas e geograficamente coerentes, porém sem nenhuma reotimização entre rotas — exatamente a lacuna que a busca local explora a seguir.

A cobertura total é garantida estruturalmente: o laço externo só termina quando não há clientes não roteados, e cada iteração roteia ao menos a semente. A viabilidade é garantida porque apenas inserções que respeitam a folga Push Forward e a capacidade são consideradas (linha 8). A Figura 1 ilustra a montagem de uma rota.




Figure 1 – Construção por inserção I1: a rota começa pela semente (cliente mais distante do depósito) e recebe, a cada passo, o cliente que maximiza c_2 , até nenhuma inserção viável restar. O cliente recém-inserido está em amarelo.

3.4 Vizinhanças e sua escolha

Adotamos um *kit* padronizado de seis operadores, compartilhado por VND, GRASP e Busca Tabu, e listado aqui na ordem em que é explorado — complexidade computacional crescente:

- **2-opt** (intra rota): inverte um subtrecho de uma rota;
- **Swap** (intra e entre rotas): troca dois clientes de posição;
- **2-opt*** (entre rotas): troca as caudas de duas rotas (Potvin and Rousseau, 1995);
- **Relocate** (intra e entre rotas): remove um cliente e o reinsere em outra posição;
- **Or-opt** (intra e entre rotas): move uma cadeia de 2–3 clientes, eventualmente invertida (Or, 1976);
- **Cross-exchange** (entre rotas): troca subtrechos de até 3 clientes entre duas rotas (Taillard et al., 1997).

Todos são operadores clássicos para o VRPTW (Toth and Vigo, 2002). Os seis cobrem os oito movimentos avaliados no relatório parcial: Relocate, Swap e Or-opt implementam as variantes *intra* e *entre* rotas numa única varredura, e o “2-opt inter” do parcial corresponde ao 2-opt* de Potvin and Rousseau (1995).

Seleção do subconjunto. Conforme previsto no relatório parcial, os oito movimentos avaliados foram submetidos a seleção por ablação nas instâncias de treino, com Wilcoxon pareado e correção de Holm (Seção 4.3): a remoção de qualquer operador piora o *gap* médio, e nenhum subconjunto próprio supera o conjunto completo. O subconjunto selecionado é, portanto, o próprio conjunto, explorado em ordem de complexidade crescente (Hansen and Mladenović, 2001), com a ordem derivada do custo medido de uma varredura completa.

Cada operador avalia a viabilidade do movimento por uma simulação completa da(s) rota(s) afetada(s), de modo que nenhum movimento inviável é jamais aplicado (Seção 3.9).

A Figura 2 ilustra o efeito de cada um.

3.5 Descida em Vizinhança Variável (VND)

O VND (Hansen and Mladenović, 2001) é o primeiro método que otimiza a Equação (3) diretamente: todo movimento aceito *reduz estritamente* a distância total $D(S)$, e a viabilidade é pré-condição de candidatura (Seção 3.9) — de modo que a trajetória de custos é monotônica decrescente e o método para, por definição, num ótimo local. Ele percorre as vizinhanças em uma ordem fixa, **da varredura mais barata à mais cara** — (2-opt, Swap, 2-opt*, Relocate, Or-opt, Cross-exchange), a ordem de complexidade medida apresentada na Seção 3.4. Ao encontrar uma melhora (estratégia de *melhor melhora*), aplica-a e reinicia da primeira vizinhança; caso contrário, avança para a próxima. Termina em um ótimo local com relação a *todas* as vizinhanças (Algoritmo 2). É determinístico dada a solução inicial.

Algoritmo 2 VND — Descida em Vizinhança Variável

Entrada: solução viável S ; lista ordenada de vizinhanças $N_1, \dots, N_p$


Saída: ótimo local S em relação a todas as vizinhanças

```
1:  $\ell \leftarrow 1$ 
2: enquanto  $\ell \leq p$  faça
3:    $m \leftarrow$  melhor movimento viável e melhorante em  $N_\ell(S)$ 
4:   se  $m$  existe (reduz estritamente a distância) então
5:      $S \leftarrow$  aplica  $m$  a  $S$ ;  $\ell \leftarrow 1$ 
6:   senão
7:      $\ell \leftarrow \ell + 1$ 
8:   fim se
9: fim enquanto
10: retorne  $S$ 
```


Leitura passo a passo. O índice ℓ (linha 1) aponta a vizinhança ativa. A linha 3 varre *toda* a vizinhança N_ℓ e retorna o melhor movimento melhorante (estratégia de *melhor melhora*, que escolhe o movimento de maior redução, não o primeiro). Se há ganho, a linha 5 o aplica e **reinicia de** $\ell = 1$: voltar à vizinhança mais barata após cada melhora é o que caracteriza o VND e o que torna a descida sistemática. Sem ganho, a linha 7 passa à vizinhança seguinte; o laço encerra quando nenhuma das p vizinhanças melhora S . A ordem por complexidade tem efeito prático direto: como cada melhora reinicia da primeira vizinhança, os operadores de varredura barata (2-opt, Swap) absorvem a maior parte dos movimentos e reduzem o trabalho que sobra para os caros (Or-opt, Cross-exchange). É o mecanismo por trás da recomendação de Hansen and Mladenović (2001) de explorar primeiro a vizinhança mais simples. Em termos da *for-*

Operadores de vizinhança (kit compartilhado): efeito de cada movimento


antes — Relocate (entre rotas): move o cliente 2




depois




antes — Swap (entre rotas): troca 2 e 5




depois




antes — 2-opt (intra rota): inverte o trecho 2-3




depois




antes — Or-opt (entre rotas): move a cadeia 2-3



depois



antes — Cross-exchange: troca {2} por {5,6}



depois




Figure 2 – Os cinco operadores de vizinhança (antes/depois), em um exemplo esquemático com duas rotas (azul e vermelha) e o depósito (D); os clientes destacados em amarelo são os que cada movimento desloca.

mação da solução, é aqui que a rota rígida da I1 começa a ser reorganizada: o 2-opt desfaz cruzamentos *dentro* de uma rota, o 2-opt* recombina as *caudas* de duas rotas (podendo até fundi-las), o Relocate corrige clientes mal alocados e o Or-opt e o Cross-exchange transferem trechos *entre* veículos. O ganho quantitativo sobre a I1 é apresentado na Seção 4.4; o VND permanece, porém, preso ao primeiro ótimo local encontrado — a limitação que motiva as meta-heurísticas a seguir.

A Figura 3 ilustra a busca local em ação: cada painel é a solução após um movimento, com a distância caindo monotonicamente até o ótimo local.




Figure 3 – Evolução das rotas na instância C101 ao longo dos movimentos da busca local (VND): cada painel mostra a solução após um movimento, com o custo decrescendo de 888,0 a 827,3 (o melhor conhecido).

3.6 GRASP

O GRASP (Feo and Resende, 1995; Resende and Ribeiro, 2003) repete um ciclo *construção gulosa-aleatorizada* → *busca local* e guarda a melhor solução. Sua função-objetivo é a mesma Equação (3), atacada por *multi-partida*: cada iteração produz um ótimo local independente e o resultado é $S^* = \arg \min_i D(S_i)$ sobre todas as iterações — a qualidade final é, portanto, monotonicamente não decrescente no número de iterações (Resende and Ribeiro, 2003). A construção reusa a I1, mas substitui a escolha gulosa do melhor cliente por uma seleção aleatória dentro de uma **Lista Restrita de Candidatos** (RCL) baseada em valor: dado o conjunto de candidatos com valores c_2 ,

sejam $c^{\max}$ e $c^{\min}$ o maior e o menor; a RCL contém todo candidato com

$$c_2(u) \geq c^{\max} - \alpha(c^{\max} - c^{\min}), \quad \alpha \in [0, 1]. \quad (7)$$

Com $\alpha = 0$ recupera-se a construção gulosa; com $\alpha = 1$, totalmente aleatória. A Figura 4 ilustra a seleção. A busca local é o VND (Algoritmo 2). O Algoritmo 3 resume o método; α é o único parâmetro, calibrado por *irace*.




Figure 4 – Seleção da RCL no GRASP: os candidatos com c_2 acima do limiar $c^{\max} - \alpha(c^{\max} - c^{\min})$ (aqui 6,2, com $\alpha = 0,3$) entram na lista (verde) e um deles é sorteado uniformemente; os demais são descartados.

Algoritmo 3 GRASP (Feo & Resende)

Entrada: instância; parâmetro α ; orçamento K (iterações sem melhora)

Saída: melhor solução S^*

```

1:  $S^* \leftarrow l1$   $\triangleright$  partida comum a todos os métodos (Seção 3.3);  $k \leftarrow 0$ 
2: enquanto critério de parada não satisfeito faça
3:    $S \leftarrow$  ConstruçãoGulosa-Aleatorizada( $\alpha$ )
4:    $S \leftarrow$  VND( $S$ )
5:   se distância( $S$ ) < distância( $S^*$ ) então
6:      $S^* \leftarrow S$ ;  $k \leftarrow 0$ 
7:   senão
8:      $k \leftarrow k + 1$ 
9:   fim se
10:  se  $k \geq K$  então
11:    interrompa
12:  fim se
13: fim enquanto
14: retorne  $S^*$ 

```

Leitura passo a passo. A linha 1 difere da forma de livro-texto (que parte de incum-

bente vazio) em um ponto deliberado: o incumbente inicial é a solução da I1 pura, a mesma partida entregue ao VND e à Busca Tabu. Com isso, o resultado do GRASP nunca é pior que a I1 por garantia, e não por observação empírica — e a comparação entre os métodos parte do mesmo ponto. Cada iteração é então um ciclo *construção* → *busca local*: a linha 3 gera uma solução nova com aleatorização controlada por α (a RCL da Figura 4), e a linha 4 a conduz a um ótimo local pelo VND (Algoritmo 2). A aleatorização age apenas na escolha de qual cliente inserir; a regra de semente e o critério c_2 permanecem os da I1, e é por isso que, com $\alpha = 0$, o GRASP reproduz a I1 exatamente — propriedade verificada por teste automatizado nas 56 instâncias. A linha 6 retém a melhor solução já vista e zera o contador de estagnação; a linha 8 o incrementa quando não há ganho; e a linha 11 encerra após K iterações sem melhora. O que o GRASP acrescenta à formação da solução é *diversificação estruturada*: ao reconstruir a rota do zero a cada iteração, ele rompe a dependência da semente única da I1 — cada RCL produz uma topologia de rotas diferente —, e o resultado final é a melhor entre centenas de descidas independentes (Seção 4.4).

3.7 GRASP Reativo

O GRASP Reativo (Prais and Ribeiro, 2000) otimiza a mesma função-objetivo do GRASP — Equação (3), por multi-partida — diferindo apenas em *como* o parâmetro de aleatorização é escolhido: em vez de um α fixo, mantém-se um conjunto discreto $\{\alpha_1, \dots, \alpha_g\}$ (grade 0,05, 0,10, ..., 0,50) com probabilidades p_i de seleção. A cada bloco de *block* iterações, as probabilidades são atualizadas de modo que valores de α que produziram soluções melhores fiquem mais prováveis:

$$q_i = \left(\frac{Z^*}{\bar{Z}_i} \right)^\delta, \quad p_i = \frac{q_i}{\sum_j q_j}, \quad (8)$$

onde Z^* é o melhor custo encontrado e $\bar{Z}_i$ o custo médio (acumulado ao longo de toda a execução) das soluções obtidas com α_i . Os parâmetros δ (expoente) e *block* são calibrados por *irace*. O Algoritmo 4 detalha o método; nas primeiras g iterações cada α é experimentado uma vez (*aquecimento*) antes de a amostragem por probabilidade começar.

Algoritmo 4 GRASP Reativo (Prais & Ribeiro)

Entrada: grade $\{\alpha_1, \dots, \alpha_g\}$; expoente δ ; tamanho de bloco $block$; orçamento K

Saída: melhor solução S^*

```

1:  $p_i \leftarrow 1/g$ ,  $\Sigma_i \leftarrow 0$ ,  $n_i \leftarrow 0$  para todo  $i$ ;  $S^* \leftarrow \text{I1}$ ;  $k \leftarrow 0$ ;  $it \leftarrow 0$ 
2: enquanto critério de parada não satisfeito faça
3:   se  $it < g$  então
4:      $j \leftarrow it + 1$   $\triangleright$  aquecimento: cada  $\alpha$  uma vez
5:   senão
6:      $j \leftarrow$  amostra de  $\{1, \dots, g\}$  segundo as probabilidades  $p$ 
7:   fim se
8:    $S \leftarrow \text{VND}(\text{ConstruçãoGulosa-Aleatorizada}(\alpha_j))$ 
9:    $c \leftarrow \text{distância}(S)$ ;  $\Sigma_j \leftarrow \Sigma_j + c$ ;  $n_j \leftarrow n_j + 1$ 
10:  se  $c < \text{distância}(S^*)$  então
11:     $S^* \leftarrow S$ ;  $k \leftarrow 0$ 
12:  senão
13:     $k \leftarrow k + 1$ 
14:  fim se
15:   $it \leftarrow it + 1$ 
16:  se  $k \geq K$  então
17:    interrompa
18:  fim se
19:  se  $it \bmod block = 0$  então
20:    para todo  $i$  com  $n_i > 0$ :  $\bar{Z}_i \leftarrow \Sigma_i / n_i$ ,  $q_i \leftarrow (Z^* / \bar{Z}_i)^\delta$ 
21:     $p_i \leftarrow q_i / \sum_l q_l$  para todo  $i$ 
22:  fim se
23: fim enquanto
24: retorne  $S^*$ 

```

Leitura passo a passo. O reativo difere do GRASP por *aprender* qual α funciona melhor em cada instância. As linhas 4–6 escolhem o α : nas primeiras g iterações cada valor é testado uma vez (aquecimento, para que nenhum α comece com vantagem espúria); depois, α é sorteado conforme as probabilidades p . A linha 9 acumula o custo médio obtido por cada α e, a cada $block$ iterações, as linhas 20–21 recalculam as probabilidades pela razão $q_i = (Z^* / \bar{Z}_i)^\delta$ — valores de α que produziram soluções melhores tornam-se mais prováveis. Na formação da solução, isso ajusta automaticamente o equilíbrio guloso↔aleatório ao perfil da instância; se esse aprendizado se traduz em vantagem mensurável sobre o GRASP de α fixo é uma pergunta empírica, respondida pela análise estatística da Seção 4.4.

3.8 Busca Tabu

Adotamos a forma clássica e mais simples da Busca Tabu (Glover, 1989, 1990): a cada iteração, move-se para o *melhor vizinho admissível* sobre o kit de vizinhanças, aceitando, se necessário, movimentos que pioram a solução, para escapar de ótimos locais. A função-objetivo é a mesma Equação (3), com uma distinção operacional: a solução *corrente* pode piorar de um passo para o outro; quem realiza a minimização é o *incumbente* S^* , que retém o menor $D(S)$ visitado ao longo da trajetória única do método. Um movimento é *tabu* se algum cliente que ele toca foi movido nas últimas *tenure* iterações, a menos que satisfaça o critério de *aspiração por objetivo* (produzir um novo melhor global). Adota-se também a *aspiração por omissão* (Glover, 1990): se **todos** os movimentos disponíveis estiverem tabu, revoga-se o status do grupo de clientes com prazo de expiração mais próximo e a varredura é refeita, em vez de encerrar a busca — sem ela, a lista tabu pode esgotar a vizinhança e truncar a execução muito antes do critério de parada. O atributo tabu é o cliente movido; é uma simplificação deliberada (em vez do arco/atributo de movimento), mantida para preservar a forma “de livro-texto”. Não há religação de caminhos, intensificação ou diversificação por frequência. O único parâmetro é *tenure*, calibrado por *irace* (Algoritmo 5).

Algoritmo 5 Busca Tabu (Glover, forma clássica)

Entrada: solução inicial S (da I1); *tenure*; orçamento K

Saída: melhor solução S^*

```
1:  $S^* \leftarrow S$ ;  $k \leftarrow 0$ 
2: enquanto critério de parada não satisfeito faça
3:    $m \leftarrow$  melhor movimento viável e admissível em  $N(S)$   $\triangleright$  não-tabu, ou tabu com aspiração
4:   se não existe movimento admissível então
5:     revogue o status tabu do grupo com menor prazo de expiração; refaça a varredura  $\triangleright$  aspiração por omissão
6:   fim se
7:    $S \leftarrow$  aplica  $m$  a  $S$ ; marque o(s) cliente(s)-atributo de  $m$  como tabu por tenure iterações
8:   se distância( $S$ ) < distância( $S^*$ ) então
9:      $S^* \leftarrow S$ ;  $k \leftarrow 0$ 
10:  senão
11:     $k \leftarrow k + 1$ 
12:  fim se
13:  se  $k \geq K$  então
14:    interrompa
15:  fim se
16: fim enquanto
17: retorne  $S^*$ 
```

Leitura passo a passo. A cada iteração, a linha 3 varre todo o kit de vizinhanças e escolhe o melhor movimento *admissível* — não-tabu ou, se tabu, que satisfaça a aspiração por objetivo. Diferentemente do VND, a Tabu **não** exige que o movimento melhore: a linha 7 pode aplicar uma piora controlada, e é assim que a busca escapa de ótimos locais. O movimento torna tabu, por *tenure* iterações, o(s) cliente(s) que ele toca (memória de curto prazo), o que impede a busca de reverter movimentos recentes e ciclar. Quando a lista tabu chega a bloquear *todos* os movimentos — situação comum com *tenure* alto em instâncias pequenas —, a linha 5 aplica a aspiração por omissão: expira o grupo de proibições mais antigo e repete a varredura, sem consumir iteração; a busca só termina pelo critério de parada. A linha 9 guarda o melhor já visto. Na formação da solução, a Tabu percorre uma *única* trajetória contínua, refinando a estrutura herdada da I1 sem reinícios — em contraste com o GRASP, que explora múltiplas estruturas independentes; a comparação quantitativa está na Seção 4.4.

3.9 Critérios de aceitação — “as regras do jogo”

Os cinco métodos diferem essencialmente em *o que aceitam* a cada passo. Tornamos isso explícito:

- **Filtro de viabilidade (comum a todos).** Um movimento só é *candidato* se a(s) rota(s) resultante(s) satisfaz(em) a Equação (1). Movimentos inviáveis são descartados *antes* da comparação de custo. Esse filtro é o que garante o invariante da Seção 2.3.
- **VND e GRASP:** aceitam um movimento apenas se ele *reduz estritamente* a distância (melhora). O GRASP, além disso, guarda a melhor solução ao longo das reinicializações.
- **Busca Tabu:** aceita, a cada iteração, o *melhor vizinho admissível*, mesmo que piore a solução corrente; a regra tabu proíbe reverter movimentos recentes (memória de curto prazo), e a aspiração libera um movimento tabu se ele gerar um novo melhor global.
- **RCL (GRASP):** na construção, um candidato é aceito na lista restrita se seu valor c_2 está dentro de uma fração α do intervalo $[c^{\min}, c^{\max}]$; a escolha final é uniforme sobre a RCL.

3.10 Exemplos ilustrativos do funcionamento

Para tornar concretos os mecanismos centrais, apresentamos três exemplos mínimos e verificáveis.

(a) Critério Push Forward (viabilidade de inserção em $O(1)$). Considere o depósito $D = (0, 0)$, horizonte $[0, 100]$, e a rota $\langle D, A, B, D \rangle$ com $A = (10, 0)$, janela $[5, 40]$, serviço 5; $B = (30, 0)$, janela $[20, 60]$, serviço 5; capacidade $Q = 50$ e demandas 10. As distâncias são $d_{DA} = 10$, $d_{AB} = 20$, $d_{BD} = 30$. A Tabela 1 mostra o cronograma: partindo de D em $t = 0$, todos os inícios respeitam as janelas e o retorno ocorre em $70 \leq 100$. A *folga (slack)* de cada cliente é a margem de adiamento do seu início sem violar nada à frente: $\text{slack}(B) = \min(60 - 35, 100 - 70) = 25$ e $\text{slack}(A) = \min(40 - 10, 0 + 25) = 25$.

Table 1 – Cronograma da rota $\langle D, A, B, D \rangle$ do exemplo (a).

nó	chegada	início	partida	janela
A	10	10	15	$[5, 40]$
B	35	35	40	$[20, 60]$
D (retorno)	70	—	—	$[0, 100]$

Suponha inserir $C = (15, 0)$, janela $[10, 50]$, serviço 5, demanda 10, entre A e B . Verifica-se em $O(1)$: a capacidade ($20 + 10 \leq 50$); o início de C , $\max(15 + 5, 10) = 20 \leq 50$; e o novo início de B , $\max(25 + 15, 20) = 40$, um *deslocamento* de $40 - 35 = 5$. Como $5 \leq \text{slack}(B) = 25$, a inserção é **viável** — sem reavaliar a rota inteira. É exatamente esse teste que cada operador de melhoria aplica antes de aceitar um movimento.

(b) Lista Restrita de Candidatos (GRASP). Suponha quatro candidatos com valores c_2 : $u_1=8,0$, $u_2=6,5$, $u_3=5,0$, $u_4=2,0$, logo $c^{\max}=8,0$ e $c^{\min}=2,0$. Com $\alpha = 0,3$, o limiar é $8,0 - 0,3 \cdot (8,0 - 2,0) = 6,2$; assim $\text{RCL} = \{u_1, u_2\}$ e o próximo cliente é sorteado uniformemente entre os dois. Com $\alpha = 0$ a RCL seria $\{u_1\}$ (guloso puro); com $\alpha = 1$ conteria todos (aleatório puro). É esse parâmetro que regula o equilíbrio guloso–aleatório, calibrado por *irace*.

(c) Uma iteração da Busca Tabu. Da solução corrente, a varredura encontra como melhor movimento *viável e admissível* um Relocate do cliente 7, com variação de distância $\Delta = -3,1$. Aplica-se o movimento e o cliente 7 torna-se *tabu* por *tenure* iterações: nesse período, qualquer movimento que toque o cliente 7 é proibido — *exceto* se produzir um custo melhor que o melhor global já visto (aspiração). Assim, a busca aceita pioras controladas para escapar de ótimos locais, mas evita ciclar revertendo movimentos recentes.

3.11 Parametrização

Cada parâmetro deste estudo pertence a uma de três categorias, e a categoria determina como seu valor foi obtido. Parâmetros **fixos** definem o terreno comum da com-

paração — a solução inicial, o conjunto de vizinhanças, a convenção de distância — e por isso não podem ser ajustados por método: calibrá-los daria a um algoritmo uma condição de partida diferente da dos demais. Parâmetros **calibrados** são os de qualidade intrínsecos a cada meta-heurística, ajustados pelo *irace* sobre as instâncias de treino (Seção 3.13); seus valores finais ficam registrados em `experiments/config/tuned.json` e não são transcritos à mão para este texto. Parâmetros **declarados** são orçamentos computacionais, para os quais não existe valor ótimo a descobrir (Seção 3.12). A Tabela 2 consolida as três categorias.

Table 2 – Parâmetros dos algoritmos: papel, valor ou intervalo de busca, e origem de cada um.

Algoritmo	Parâmetro	Papel	Valor / intervalo
I1	μ	economia do arco removido em c_{11}	1,0
I1	λ	peso da distância ao depósito em c_2	2,0
I1	α_1, α_2	mistura distância×tempo em c_1	1,0 / 0,0
I1	semente	cliente que abre cada rota	mais distante
VND	ordem	sequência de exploração das vizinhanças	complexidade me
GRASP	α	largura da RCL (guloso↔aleatório)	(0; 0,5)
Reativo	δ	expoente da reponderação das probabilidades	(0,5; 3,0)
Reativo	<i>block_frac</i>	cadência de reponderação, fração de K	(0,02; 0,40)
Reativo	grade de α	valores candidatos ao sorteio	0,05–0,50 (10)
Tabu	<i>tenure</i>	duração da proibição (memória curta)	(5; 80)
todos	K	iterações sem melhoria (parada)	800
todos	teto de tempo	salvaguarda de execução	600 s

Quatro escolhas da tabela merecem justificativa explícita. Os parâmetros da I1 usam a configuração de distância de Solomon (1987) ($\alpha_2 = 0$), coerente com o objetivo DIMACS, e são fixos porque a I1 é a partida comum de todos os métodos. O intervalo de α do GRASP para em 0,5 porque, acima disso, a construção degenera em sorteio quase uniforme e perde a estrutura da I1 que a busca local aproveita. O *block_frac* do Reativo é expresso como fração de K , e não em iterações absolutas, para que o número de reponderações independa do orçamento — com bloco absoluto, um orçamento pequeno pode encerrar a execução antes da primeira reponderação, e o mecanismo reativo simplesmente não opera. O teto do *tenure* foi definido após uma primeira rodada de calibração em que o vencedor caiu na fronteira superior do intervalo então vigente; um vencedor de fronteira indica intervalo curto, e a resposta metodológica é alargá-lo e repetir a corrida, não reportar o valor de borda como ótimo.

3.12 Critério de parada

A I1 e o VND são determinísticos e terminam naturalmente (a I1 quando todos os clientes estão roteados; o VND em um ótimo local). Para as meta-heurísticas estocásticas/iterativas (GRASP, GRASP Reativo e Busca Tabu) adotamos como critério primário o **número de iterações consecutivas sem melhora do incumbente (K)**, na unidade natural de iteração de cada método (uma iteração do GRASP é uma construção seguida de VND; uma iteração da Tabu é um movimento). O tempo de relógio é registrado e reportado, mas serve apenas como teto de segurança. Essa escolha favorece a **reprodutibilidade** (uma parada por tempo depende da máquina), ao custo de que uma “iteração” não representa o mesmo esforço entre métodos; por isso reportamos também o tempo e o número de iterações de cada execução, e as curvas tempo-alvo (TTT), tornando o esforço transparente. Observa-se que a *competição* DIMACS em si pontua por tempo de relógio padronizado e integral primal (DIMACS, 2022); como este trabalho é um *estudo comparativo* (não uma submissão à competição), adotar a parada por iterações sem melhoria é uma opção metodológica deliberada em favor da reprodutibilidade, mantendo a mesma convenção de distância e objetivo do desafio.

3.13 Calibração de parâmetros (irace)

A calibração é feita com o pacote *irace* (López-Ibáñez et al., 2016), padrão de fato para configuração automática de algoritmos. Para evitar superajuste, as 56 instâncias são divididas em **treino** (28) e **teste** (28), estratificadas por família (C/R/RC) e tipo (1/2); o *irace* usa apenas o treino, e os resultados são reportados no teste e no conjunto completo. Adotamos um desenho **desacoplado**: o critério de parada K é **declarado** (a seguir), e o *irace* calibra *apenas* os hiperparâmetros de qualidade de cada método — GRASP: α ; Reativo: δ e *block_frac*; Tabu: *tenure*. Os demais elementos (parâmetros da I1, conjunto de vizinhanças, número de execuções) são *fixados* por justiça. A função-objetivo do *irace* é o *gap* de distância ao melhor valor conhecido, que normaliza escalas entre instâncias. A justificativa de cada faixa de busca e da separação “calibrar vs. fixar” está documentada no arquivo TUNING_RATIONALE.

Fixação de K . O critério de parada K é um *orçamento*, não um parâmetro de qualidade: mais iterações sem melhora nunca pioram o gap. Essa monotonicidade tem uma consequência que precisa ser enunciada, porque ela decide o procedimento: **não existe valor ótimo de K a ser descoberto**. Um orçamento monótono não pode ser escolhido minimizando o objetivo — calibrá-lo pelo gap, junto aos parâmetros de qualidade, o levaria sempre ao teto do intervalo de busca, conflacionando *orçamento* e

qualidade. É também o motivo pelo qual a literatura de GRASP e de Busca Tabu não deriva K : ela o *declara* (Feo and Resende, 1995; Resende and Ribeiro, 2003; Prais and Ribeiro, 2000).

Adotamos, portanto, K como **orçamento computacional declarado**, *uniforme entre os métodos* — $K_{\text{GRASP}} = K_{\text{Reativo}} = K_{\text{Tabu}} = 800$ — de modo que a regra de parada seja a mesma para todos. A Tabela 3 mostra, nas instâncias de treino, o que cada orçamento entrega e o que custa. Em $K = 800$ a execução mediana leva 15,6 s no GRASP, 22,7 s no Reativo e 6,8 s na Busca Tabu, com pior caso de 76 s — folgadoamente dentro do teto de segurança de 600 s. Dobrar o orçamento para $K = 1600$ reduz o gap do GRASP em 0,19 ponto percentual e custa 1,8× mais tempo (2,3× no Reativo).

A escolha não influencia nenhuma conclusão do estudo, e isso é verificado e não suposto: **o ordenamento dos métodos e o resultado dos testes par a par são idênticos em toda a faixa medida**, de $K = 50$ a $K = 3200$ — uma variação de 64× (Apêndice B). A contrapartida de um K uniforme é que uma “iteração” não custa o mesmo em cada método; por isso reportamos o tempo, o número de iterações e as curvas tempo-alvo (TTT), e complementamos a leitura com a comparação sob tempo igual e o integral primal.

Table 3 – O que cada orçamento de parada entrega e o que custa, nas 28 instâncias de treino. *Gap*: distância percentual média ao melhor valor conhecido. *Tempo*: mediana por execução, medida sem concorrência. O valor adotado ($K = 800$) está em negrito. Não há platô: o gap continua caindo até o fim da faixa medida, o que é a razão de K ser declarado como orçamento e não derivado de um joelho inexistente.

K	gap médio (%)			tempo mediano (s)		
	GRASP	Reativo	Tabu	GRASP	Reativo	Tabu
50	3.49	3.11	5.99	—	—	—
100	3.15	2.71	5.47	—	—	—
200	2.39	2.27	4.68	4.6	6.9	1.6
400	2.17	1.93	4.28	9.5	11.8	3.9
800	1.86	1.65	4.04	15.6	22.7	6.8
1600	1.67	1.52	3.64	27.9	52.5	13.9
3200	1.47	1.20	3.28	—	—	—

3.14 Comparação estatística

Cada algoritmo estocástico é executado 30 vezes por instância, com sementes independentes registradas; os determinísticos (I1, VND, Busca Tabu) executam uma vez, por não possuírem fonte de aleatoriedade. Para comparar os métodos sobre as 56 instâncias usamos o teste não-paramétrico de **Friedman** sobre os *ranks* por instância

(variável-resposta: gap médio), seguido do pós-teste de **Nemenyi** (todas as comparações par a par), conforme Demšar (2006). A estatística de Friedman, *com correção para empates* (frequentes, pois na família C vários métodos atingem o ótimo), é

$$\chi_F^2 = \frac{1}{C} \cdot \frac{12N}{k(k+1)} \left[\sum_{j=1}^k R_j^2 - \frac{k(k+1)^2}{4} \right], \quad C = 1 - \frac{\sum_g (t_g^3 - t_g)}{N(k^3 - k)}, \quad (9)$$

com N instâncias, k algoritmos, R_j o *rank* médio do algoritmo j (rank 1 = melhor) e t_g o tamanho de cada grupo de empate. A correção para empates é relevante neste conjunto: na família C vários métodos atingem o mesmo custo, e ignorá-la subestimaria a estatística. É o cálculo realizado pela implementação (`scipy.stats.friedmanchisquare`). No pós-teste de Nemenyi, dois algoritmos diferem significativamente se seus ranks médios distam mais que a *diferença crítica*

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6N}}, \quad (10)$$

onde q_α é o valor crítico do *range* estudentizado (dividido por $\sqrt{2}$); para $k = 5$ e $\alpha = 0,05$ ($q_\alpha = 2,728$), tem-se $CD = 0,815$ com $N = 56$. Os resultados são sintetizados em um *diagrama de diferença crítica* (CD). O teste de Friedman é apropriado por ser pareado (mesmas instâncias para todos os métodos) e robusto a distribuições não-normais dos gaps.

O pós-teste de Nemenyi opera sobre *ranks médios*, e uma limitação conhecida dessa família de procedimentos é que a conclusão sobre um par de métodos depende também do desempenho dos demais métodos incluídos na comparação (Benavoli et al., 2016). Por isso, cada comparação par a par de interesse é adicionalmente examinada pelo teste de **Wilcoxon pareado** sobre os gaps por instância, com correção de **Holm** para as múltiplas comparações (García and Herrera, 2008) — um procedimento que usa apenas os dados do próprio par. As duas leituras são reportadas; conclusões afirmadas no texto exigem concordância entre ambas.

3.15 Ambiente computacional e reprodutibilidade

Os experimentos foram conduzidos em uma única máquina — Intel® Core™ Ultra 9 285K (24 *threads*), Ubuntu 24.04 LTS (kernel 6.17), com o solver compilado por g++ 13.3 e `-std=c++20 -O2`. Cada execução é reprodutível a partir da semente registrada, pelo protocolo portátil descrito na Seção 3.2. A convenção de distância e a corretude do avaliador são verificadas contra soluções de referência (Seção 4.1).

4 Resultados e Discussão

O desempenho é medido pelo *gap* percentual de distância ao melhor conhecido,

$$\text{gap}(\%) = 100 \cdot \frac{d - d^{\text{bk}}}{d^{\text{bk}}}, \quad (11)$$

onde d é a distância obtida e d^{bk} a da solução de referência (Seção 4.6); o *gap* normaliza as escalas entre instâncias de tamanhos e densidades diferentes. Reportamos o *gap médio* (sobre as 30 execuções dos métodos estocásticos) e o *melhor*.

4.1 Verificação da convenção de distância

Antes de qualquer comparação, validamos a implementação reproduzindo o custo das 56 soluções de referência. Recomputando a distância de cada solução de referência sob a convenção truncada, obtemos os custos declarados em **todas as 56 instâncias** (tolerância $\leq 0,05$). Esse teste é um *portão*: nenhum resultado é considerado antes de ele passar.

4.2 Viabilidade das soluções

Em todas as execuções do estudo (construção, VND, GRASP, Reativo e Tabu, em todas as instâncias e sementes; a contagem exata por método é registrada em `results/run_counts`) o verificador independente não acusou **nenhuma** solução inviável, e nenhum *gap* negativo (distância inferior à referência) ocorreu. Isso confirma, empiricamente, o invariante da Seção 2.3: os algoritmos de melhoria formam e modificam rotas *sem jamais violar* cobertura, capacidade ou janelas de tempo.

4.3 Ablação do conjunto de vizinhanças

A Tabela 4 quantifica a contribuição de cada operador por *ablação leave-one-out*: o VND é executado com o kit completo e, em seguida, seis vezes com um operador removido de cada vez, sempre sobre as mesmas 28 instâncias de treino e a partir da mesma solução inicial I1 — de modo que a única diferença entre as linhas é a presença do operador. Três métricas acompanham cada remoção: o **gap médio** resultante, o **placar por instância** (em quantas a remoção piora, melhora ou empata) e o *p-valor* do teste de Wilcoxon pareado com correção de Holm para múltiplas comparações.

Table 4 – Ablação *leave-one-out* do conjunto de vizinhanças (VND, 28 instâncias de treino): efeito de remover cada operador do kit completo, com o placar por instância e o p de Wilcoxon pareado sob correção de Holm. A remoção de qualquer operador piora o gap médio; a última coluna mostra que o teste tem poder limitado para os operadores que afetam poucas instâncias.

Configuração	Gap médio (%)	Δ (pp)	piora/melhora/empata	p (Holm)	s
Kit completo (6 operadores)	8,25	—	—	—	
sem Relocate	11,40	+3,15	23/4/1	0,0015	
sem 2-opt*	9,67	+1,42	16/6/6	0,1745	
sem 2-opt intra	9,25	+1,00	8/8/12	0,7476	
sem Swap	9,23	+0,98	13/8/7	0,5349	
sem Or-opt	9,01	+0,76	12/1/15	0,0216	
sem Cross-exchange	8,75	+0,50	4/0/24	0,5349	

A remoção de qualquer operador piora o gap médio, o que sustenta a adoção do kit completo como resultado do procedimento de seleção (Seção 3.4). O Relocate é o operador dominante: sua remoção custa +3,15 pp e piora 23 das 28 instâncias ($p = 0,0015$). Em seguida vem o 2-opt* (+1,42 pp), cuja ausência pesa sobretudo nas famílias R e RC, onde a recombinação de caudas entre rotas é mais valiosa. Note-se que apenas Relocate e Or-opt atingem significância estatística, e que isso não autoriza remover os demais. O Cross-exchange ilustra o porquê: ele altera o resultado em somente 4 das 28 instâncias (as outras 24 empatam exatamente), e com quatro observações não nulas o teste de Wilcoxon não alcança $p < 0,05$ nem no melhor cenário possível — a falta de significância aqui é falta de *poder* do teste, não indício de que o operador seja dispensável. A busca exaustiva sobre os 63 subconjuntos, que não depende de teste de hipótese, aponta na mesma direção: os melhores subconjuntos por família diferem entre si, e sua união é o conjunto completo.

4.4 Comparação de desempenho

Sob o critério de parada por iterações sem melhoria ($K = 800$ para os três métodos; Seção 3.13), com os parâmetros calibrados por *irace* (valores em `experiments/config/tuned.json`), executamos as 56 instâncias (30 execuções para os métodos estocásticos). A Tabela 5 resume o desempenho global e a Tabela 6 o detalha por família. O tempo e o número de iterações são reportados para tornar transparente o esforço de cada método (uma iteração do GRASP é muito mais cara que uma da Tabu).

Table 5 – Desempenho global nas 56 instâncias (gap de distância ao melhor conhecido).

Algoritmo	Gap médio (%)	Gap melhor (%)	Veículos	Iterações	Tempo (s)
Solomon I1	35,97	35,97	8,46	—	< 0,01
VND	11,07	11,07	8,38	—	0,04
GRASP	3,40	1,92	8,21	390	15,3
GRASP reativo	3,38	2,00	8,28	390	18,5
Busca Tabu	4,51	4,51	8,29	1942	11,6

Table 6 – Gap médio de distância por família (%).

Algoritmo	C (agrupada)	R (aleatória)	RC (mista)
Solomon I1	26,58	37,28	44,05
VND	4,46	13,42	14,73
GRASP	0,23	4,33	5,43
GRASP reativo	0,24	4,34	5,36
Busca Tabu	0,74	5,37	7,29

Significância estatística. O teste de Friedman rejeita fortemente a hipótese de igualdade entre os métodos ($\chi^2 = 184,24$, $p \approx 9,2 \times 10^{-39}$, 56 instâncias). Os *ranks* médios (menor é melhor) são: GRASP 1,82, GRASP reativo 1,91, Busca Tabu 2,48, VND 3,79 e I1 5,00. O pós-teste de Nemenyi (Figura 5) indica que **GRASP, GRASP reativo e Busca Tabu não diferem significativamente entre si** — o menor p entre os três pares é 0,18 (GRASP $\times$ Tabu), e suas diferenças de *rank* ficam abaixo da diferença crítica $CD = 0,815$ — enquanto **todos são significativamente superiores a VND e I1** ($p < 0,001$). O mesmo padrão se confirma no conjunto de teste, livre de superajuste da calibração (28 instâncias; $\chi^2 = 96,20$, $p \approx 6,3 \times 10^{-20}$; as três meta-heurísticas permanecem indistinguíveis, $p \geq 0,29$).




Figure 5 – Diagrama de diferença crítica (Friedman/Nemenyi, 56 instâncias). Métodos unidos por uma barra horizontal não diferem significativamente ($p > 0,05$).

Convergência e tempo-alvo (TTT). A Figura 6 ilustra a queda do custo ao longo do tempo na instância R101. A análise tempo-alvo na mesma instância (Figura 7), com alvo a 1% do melhor conhecido, mostra que 100% **das 100 execuções independentes atingiram o alvo**, com a distribuição empírica do tempo necessário — evidência da robustez do GRASP.




Figure 6 – Convergência do custo (distância) ao longo do tempo na instância R101.




Figure 7 – Tempo-alvo (TTT) do GRASP em R101: probabilidade acumulada de atingir o alvo (1% do melhor conhecido) em função do tempo; 100 execuções.

4.5 Análise complementar: integral primal (DIMACS)


A comparação primária deste estudo usa parada por iterações sem melhoria (Seção 3.12), por reprodutibilidade. Como *complemento*, avaliamos a dimensão *anytime* (tempo $\times$

qualidade) pela métrica oficial da *competição* DIMACS, o **integral primal** (DIMACS, 2022): para um orçamento de tempo T e o melhor conhecido BKS ,


$$PI = 100 \left(\frac{\sum_i v(i-1) (t_i - t_{i-1}) + v(n) (T - t_n)}{T \cdot BKS} - 1 \right),$$

onde $v(0) = 1,1 BKS$ em $t_0 = 0$ e $v(i)$ é o valor da incumbente encontrada em t_i ; menor PI é melhor (encontra boas soluções mais cedo). Reexecutamos os métodos com orçamento de tempo *fixo* ($T = 15$ s) e os parâmetros de qualidade calibrados. **Ressalva importante:** por depender do tempo de relógio, o integral primal é *dependente da máquina*; por isso é reportado *apenas como complemento* ao estudo reprodutível, e não substitui a comparação primária por iterações.

A Figura 8a resume o integral primal médio e a Figura 8b mostra a convergência anytime em R101. O ordenamento confirma o da comparação primária: GRASP ($PI = 3,59$), GRASP reativo (3,67) e Busca Tabu (3,77) ficaram *próximos entre si*, todos com cerca de *metade* do integral primal do VND (7,66) — confirmando, também na dimensão anytime, o ordenamento da comparação primária. O VND, embora convirja quase instantaneamente, estaciona em seu ótimo local, o que penaliza fortemente seu integral primal; GRASP e GRASP reativo, que continuam melhorando ao longo do tempo, obtêm os menores valores.



(a) Integral primal médio (menor = melhor).



(b) Convergência anytime em R101.

Figure 8 – Análise complementar anytime (integral primal do DIMACS, $T = 15$ s). Métrica dependente de máquina, reportada apenas como complemento.

4.6 O baseline e a contagem de veículos

O *gap* é medido contra um conjunto de soluções de referência de **mínima distância** (convenção DIMACS), coerente com o objetivo otimizado, e disponíveis no repositório CVRPLIB (CVRPLIB, 2024) — repositório oficial do desafio. É importante ressaltar que coexistem na literatura *três* convenções de arredondamento incompatíveis: a do

DIMACS (truncamento a 1 casa decimal, adotada aqui), a do SINTEF (precisão dupla, 2 casas) e a euclidiana real (sem arredondamento); por isso, todos os custos — nossos e das referências — são (re)computados sob a *mesma* convenção DIMACS, garantindo comparabilidade. Verificamos que essas referências têm distância menor ou igual à das soluções de *mínimo número de veículos* do repositório SINTEF em todas as 56 instâncias (em 37 estritamente menor; nas demais, iguais), ao custo de utilizarem *mais* veículos. Por exemplo, em R201 a referência de distância usa 8 veículos com custo 1143,2, enquanto a de mínimo de veículos usa 4 veículos com custo 1248,4. Portanto, comparar a distância de nossas soluções com esse baseline é coerente, e a contagem “elevada” de veículos é a assinatura esperada da minimização de distância — não um defeito. A Tabela 7 reporta a visão lexicográfica (veículos e distância) por família, frente às duas referências. Observa-se que nossas soluções (GRASP) **dominam o SINTEF em distância** (média 992,2 contra 1017,8) usando mais veículos, e aproximam-se da referência de mínima distância (Dinamics, 973,2); coerentemente, nosso número de veículos situa-se entre o do SINTEF (mínimo) e o do Dinamics.

Table 7 – Visão lexicográfica por família: veículos e distância médios de nossas soluções (GRASP) e das duas referências.

Família	Nosso (GRASP)		Dinamics (mín. dist.)		SINTEF (mín. veíc.)	
	veíc.	dist.	veíc.	dist.	veíc.	dist.
C (agrupada)	6,7	714,3	6,7	714,1	6,7	714,1
R (aleatória)	8,8	1053,3	9,5	1029,6	7,5	1081,9
RC (mista)	8,9	1199,7	9,4	1167,6	7,4	1248,3
Todas	8,2	992,2	8,6	973,2	7,2	1017,8

5 Aplicação: Digital Twin para coleta de resíduos

Como terceira camada, um *Digital Twin* transfere os algoritmos *calibrados no benchmark* para um cenário de coleta de resíduos. Trata-se de uma **prova de conceito**: as localizações são reais, mas o comportamento de enchimento é simulado.

Dados e enquadramento. Usamos as localizações reais de **38 pontos de entrega voluntária (PEVs)** de coleta seletiva de Vitória/ES, obtidas do serviço de dados abertos do município, com o depósito na associação de triagem AMARIV. O *nível de enchimento* de cada lixeira é gerado por um **processo de Poisson não-homogêneo** (NHPP)

discretizado em ciclos (8 ciclos/dia $\approx$ 3 h cada). Em cada ciclo c , a intensidade é

$$\lambda(c) = \lambda_{\text{off}} + (\lambda_{\text{pico}} - \lambda_{\text{off}}) \min(1, \rho(c)), \quad \rho(c) = e^{-(h-1,5)^2} + e^{-(h-5,5)^2}, \quad h = c \bmod 8, \quad (12)$$

com $\lambda_{\text{off}} = 0,8$ e $\lambda_{\text{pico}} = 4,0$ (dois picos diários). O número de chegadas na lixeira i no ciclo é $\text{Poisson}(\lambda(c) p_i)$, com propensão heterogênea $p_i \sim \mathcal{U}(0,5; 1,5)$, e o enchimento sobe $\Delta f = \text{chegadas}/12$. Uma lixeira transborda se f atinge 1 antes de ser coletada (KPI rastreado). Ressaltamos com transparência que o *enchimento é sintético*, calibrado pela literatura de resíduos urbanos (Lozano et al., 2018; Barth et al., 2023), pois a coleta de séries reais exigiria meses de monitoramento — fora do escopo de uma Iniciação Científica. A validação com dados reais de enchimento é trabalho futuro.

5.1 Camada de comunicação LoRaWAN (simulada)

Entre os sensores e o orquestrador há uma camada de comunicação que simula os efeitos relevantes de uma rede LoRaWAN na escala de um ciclo de monitoramento. Sensores de lixeira alimentados por bateria operam tipicamente na classe A, com *up-links* não confirmados; três efeitos dessa escolha são modelados. A **perda de pacote**: cada uplink é entregue com probabilidade pdr (*packet delivery ratio*, padrão 0,98), e um pacote perdido não é retransmitido. O **ciclo de duty**: a banda ISM limita o tempo de ar de cada dispositivo (cerca de 1% na faixa EU868), o que na prática limita a frequência de transmissão — cada sensor transmite a cada *duty* ciclos, com fases sorteadas para que a rede não transmita em uníssono. A **defasagem**: o atraso fim-a-fim de um uplink (segundos) é desprezível frente a um ciclo (horas), de modo que o efeito real da latência nessa escala é a *idade* da leitura — entre transmissões, ou após uma perda, o orquestrador segue operando com a última leitura recebida.

A consequência é uma distinção que o gêmeo digital passa a representar: o roteador não decide sobre o estado físico das lixeiras, e sim sobre a *visão de rádio* desse estado. O acionamento por limiar, a demanda e a janela dinâmica usam o valor percebido; o transbordo continua contado no estado físico, que é o que ocorre na rua. Uma lixeira que cruza o limiar mas perde o uplink fica invisível ao planejamento até o próximo uplink entregue, e o transbordo que ocorrer nesse intervalo é atribuível à comunicação — um custo operacional que o modelo sem camada de rádio não capturava. Com canal perfeito ($pdr = 1$, transmissão a cada ciclo) a camada é transparente e o comportamento reproduz exatamente o do gêmeo sem ela, propriedade verificada por comparação direta das duas execuções. O efeito do canal é mensurável: no mapa R101 com 12 ciclos e o VND como roteador, degradar o canal para $pdr = 0,9$ com transmissão a

cada 2 ciclos elevou os transbordos de 35 para 104, com defasagem média de 0,52 ciclo — a qualidade da comunicação, e não apenas a do roteamento, limita o serviço.

5.2 Malha viária real (distâncias e tempos de direção)

Para realismo, além do grafo euclidiano (linha reta entre pontos), construímos um **grafo viário real**: a matriz de *distância* (metros) e a matriz de *tempo* (segundos de direção) entre o depósito e os 38 PEVs são obtidas da malha do OpenStreetMap pelo serviço de roteamento OSRM, e a geometria de 5 937 ruas é usada para visualização. O fator de circuito médio (distância rodoviária / linha reta) foi de **1,53** (até 6,9 em pares separados por água, já que Vitória é uma ilha). O solver foi estendido para aceitar matrizes *explícitas* de distância e tempo (o *benchmark* euclidiano de Solomon permanece inalterado, pois suas execuções não usam matrizes): assim o custo otimizado passa a ser a distância *rodoviária* e as janelas/espera usam o tempo *real* de direção. O cenário rodoviário é internamente consistente em *unidades físicas* — distância em metros, e tempo, janelas e serviço em segundos ($H = 6$ h, serviço = 120 s) —, independentes das unidades abstratas do *benchmark*. A Figura 9 mostra as rotas resultantes seguindo as ruas reais; rotear os 38 PEVs produziu 6 veículos, 83,6 km de percurso viário e 3,7 h de operação.

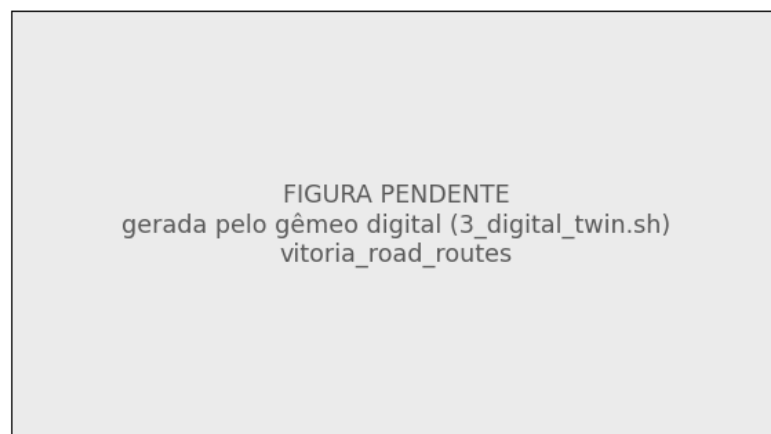


Figure 9 – Rotas do Digital Twin sobre a malha viária *real* de Vitória/ES (OSM): cada cor é um caminhão, traçado pela geometria de direção real (OSRM); a estrela é o depósito (AMARIV).

5.3 Modelo do cenário: capacidades, tempo e espera

Para que não haja qualquer ambiguidade, definimos formalmente cada elemento do cenário de coleta.

Capacidade do veículo (Q). Cada caminhão carrega no máximo Q unidades de demanda. Ao longo de uma rota, a carga acumulada é a soma das demandas das lixeiras visitadas; *nenhuma* rota pode exceder Q . Quando incluir mais uma lixeira excederia Q , a rota é fechada (o caminhão retorna ao depósito) e outro veículo é necessário — é isto que, junto com as janelas, determina o *número de veículos*.

Capacidade da lixeira e demanda. O estado de cada lixeira é o nível de enchimento $f \in [0, 1]$ (0 = vazia, 1 = cheia/transbordando). O enchimento sobe pelo processo de Poisson não-homogêneo; ao atingir 1, a lixeira *transborda* (indicador de falha de serviço). A demanda de coleta é derivada do enchimento por demanda = $\text{round}(9f)+1$ (arredondamento ao inteiro mais próximo; entre 1 e 10): é uma medida de *prioridade/volume a recolher*, *não* o peso físico — lixeiras mais cheias recebem demanda maior e ocupam mais da capacidade do veículo.

Tempo, chegada e espera. O tempo de viagem entre dois pontos é a *duração real de direção* pela malha viária (segundos, OSRM); no grafo euclidiano, é proporcional à distância (velocidade constante). Partindo do depósito em $t = 0$, a cada perna da rota: chegada = partida_{anterior} + tempo de viagem. Se a chegada ocorre *antes* da abertura da janela da lixeira (*ready*), o veículo **espera, ocioso**, até *ready*: o início de serviço é início = $\max(\text{chegada}, \text{ready})$. O serviço dura *service* segundos e partida = início + *service*. A rota deve retornar ao depósito até o fim do horizonte (*due* do depósito). Uma janela é *violada* (solução inviável) se início > *due* da lixeira. Este é exatamente o mecanismo ilustrado numericamente no exemplo da Seção 3.10(a).

Janelas de tempo dinâmicas. A cada ciclo de monitoramento, as lixeiras acima de um limiar de enchimento τ tornam-se demandas de coleta com **janela de tempo dinâmica** $[0, \text{due}]$: quanto mais cheia (mais crítica) a lixeira, mais cedo seu prazo. Formalmente, com criticidade $\text{crit} = \max(0, (f - \tau)/(1 - \tau)) \in [0, 1]$,

$$\text{due} = H (1 - \kappa \cdot \text{crit}), \quad (13)$$

onde H é o horizonte e κ (padrão 0,6) é o *coeficiente de urgência* — analisado na sensibilidade (Figura 10). Isso explora diretamente o critério Push Forward do solver (Seção 2.3), priorizando as lixeiras críticas. Constrói-se então uma instância VRPTW e invoca-se o solver (com os parâmetros calibrados) para (re)planejar as rotas; as lixeiras atendidas são esvaziadas.

O que influencia o número de veículos e o esvaziamento das rotas. Três fatores governam a operação simulada e explicam o comportamento do sistema: (i) o *limiar*

de acionamento — limiares menores acionam mais lixeiras por ciclo, exigindo mais veículos; (ii) a *capacidade do veículo* frente à *demand*a de cada lixeira (que cresce com o enchimento, como heurística de priorização) — quanto menor a razão capacidade/demanda, mais rotas; e (iii) as *janelas dinâmicas* — prazos mais apertados reduzem o compartilhamento de rotas e podem aumentar o número de veículos. Uma rota “esvazia” (e um veículo é liberado) quando os movimentos entre rotas conseguem redistribuir todos os seus clientes sem violar viabilidade.

Validação estático vs. dinâmico. Comparam-se dois regimes sobre a *mesma* realização de enchimento: o **dinâmico** (coleta sob demanda das lixeiras acima do limiar a cada ciclo) e o **estático** (coleta de todas as lixeiras a cada f ciclos, independentemente do enchimento). Os indicadores são distância total, número de coletas e **transbordos**. Como os parâmetros operacionais (limiar, capacidade, frequência f , coeficiente de urgência) são escolhas de modelagem, reportamos uma **análise de sensibilidade** variando-os, em vez de fixá-los arbitrariamente; e não estendemos as conclusões além do que a simulação suporta. Um painel interativo (*dashboard*) permite reproduzir e visualizar os ciclos.

Resultados (prova de conceito em Vitória/ES). Sobre uma simulação de 16 ciclos com a mesma realização de enchimento, o regime **dinâmico** alcançou distância comparável ao **estático** (3550,6 vs. 3566,3) com cerca de *metade das coletas* (119 vs. 228) e *menos transbordos* (16 vs. 25) — evidência de que coletar sob demanda, guiado pelos sensores, é mais eficiente que a coleta de frequência fixa (Tabela 8). Aplicando os cinco algoritmos à mesma simulação, todos os de melhoria (VND, GRASP, Reativo, Tabu) convergiram à mesma solução (3550,6), superando a construção pura I1 (3632,2): nas instâncias *pequenas* de cada ciclo a diferença entre as meta-heurísticas desaparece — as distinções observadas no *benchmark* de 100 clientes manifestam-se em escala maior.

Table 8 – Digital Twin (Vitória/ES, 16 ciclos): coleta dinâmica vs. estática (frequência fixa).

Regime	Distância	Coletas	Transbordos	Ciclos com rota
Dinâmico (sob demanda)	3550,6	119	16	14
Estático (a cada 3 ciclos)	3566,3	228	25	6

Sensibilidade dos parâmetros. Como os parâmetros do cenário são escolhas de modelagem, analisamos sua sensibilidade (Figura 10) em vez de fixá-los arbitrariamente. O *limiar de coleta* domina o compromisso serviço–custo: limiares mais altos

reduzem coletas mas aumentam transbordos (de 2 a 40 ao variar de 50% a 90%). A *capacidade* do veículo reduz fortemente a distância (de 6667 a 3097 ao variar de 15 a 40), sem afetar transbordos. O *coeficiente de urgência*, por sua vez, tem efeito agregado pequeno nos indicadores: ele atua sobretudo na *priorização* (ordem de atendimento) dentro de rotas que permanecem viáveis. Esses resultados justificam a escolha dos valores padrão e delimitam o papel de cada parâmetro.

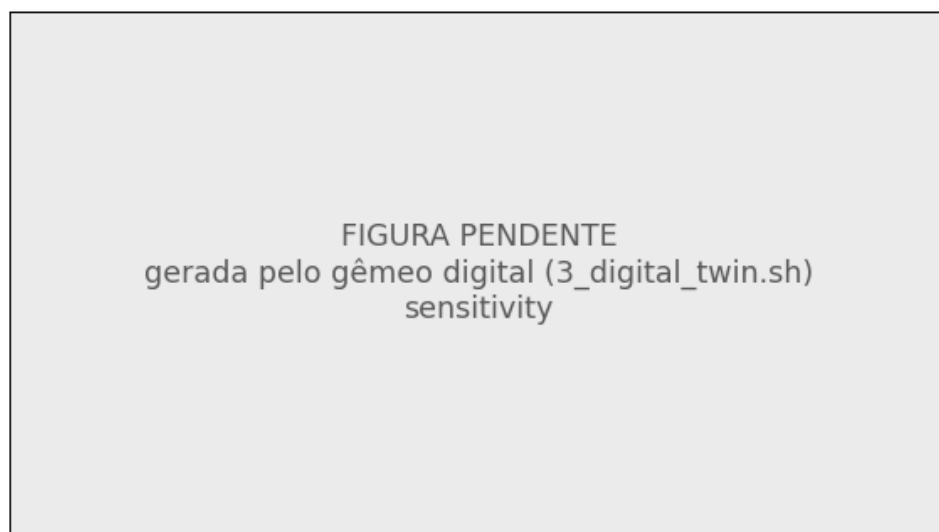


Figure 10 – Análise de sensibilidade do Digital Twin: compromisso distância (verde) × transbordos (vermelho) ao variar limiar, capacidade e coeficiente de urgência.

6 Atividades realizadas

As Etapas 1 a 3 (revisão bibliográfica, aprofundamento no algoritmo de Solomon e nas tecnologias de sensores, e definição da arquitetura) foram concluídas. A Etapa 4 (implementação dos algoritmos e do ambiente de simulação) foi concluída: o solver com os cinco métodos sobre o núcleo compartilhado está implementado, testado e verificado. A Etapa 5 (relatório parcial) foi entregue. As Etapas 6 e 7 (Digital Twin e testes computacionais) encontram-se avançadas: a calibração por *irace*, a comparação estatística nas 56 instâncias e o Digital Twin com dados reais de Vitória já estão operacionais. As Etapas 8 e 9 (análise final e relatório) estão em finalização com este documento. Em relação ao relatório parcial, houve avanço de cronograma: as atividades antes previstas como futuras (6–7) já produzem resultados.

7 Conclusão

Este trabalho estabeleceu uma comparação *justa, reprodutível e verificável* de cinco heurísticas clássicas para o VRPTW, sobre um núcleo compartilhado, com viabilidade garantida por construção e por verificação independente, parada por iterações sem melhoria (reprodutível) e comparação estatística por Friedman/Nemenyi. As escolhas metodológicas — objetivo, baseline, conjunto de vizinhanças e calibração — foram justificadas explicitamente, inclusive empiricamente (ablação) e por verificação contra referências publicadas.

Quantitativamente, as três meta-heurísticas (GRASP, GRASP reativo e Busca Tabu) mostraram-se **estatisticamente equivalentes entre si e significativamente superiores** ao VND e à construção I1, reduzindo o gap médio de distância de 35,97% (I1) e 11,07% (VND) para a faixa de 3,4–4,5% ao melhor conhecido; o GRASP obteve o melhor *rank* médio. A verificação reproduziu os 56 custos de referência e *nenhuma* das milhares de soluções produzidas foi inviável, confirmando que os algoritmos de melhoria respeitam todas as restrições a cada passo. Transportados ao Digital Twin de coleta em Vitória/ES, os mesmos algoritmos calibrados mostraram que a coleta dinâmica guiada por sensores reduz transbordos frente à coleta de frequência fixa, como prova de conceito.

Limitações. O objetivo otimizado é a distância (DIMACS); a abordagem lexicográfica de Solomon foi reportada apenas de forma complementar. A Busca Tabu foi mantida na forma mais simples (sem diversificação avançada). No Digital Twin, o enchimento das lixeiras é simulado, não medido; a comunicação LoRaWAN é representada, não validada energeticamente.

Trabalhos futuros. Validação com dados reais de enchimento em Vitória (piloto com sensores); avaliação sob o critério lexicográfico veículos→distância; variantes mais ricas (Tabu com memória de longo prazo, metaheurísticas híbridas/ILS); e quantificação de benefícios econômicos e ambientais.

A Resultados detalhados por instância

A Tabela 9 apresenta, para cada uma das 56 instâncias, a comparação dos cinco algoritmos nas métricas: número de veículos, custo (distância média), gap percentual ao melhor conhecido, número de iterações e tempo. Para os algoritmos estocásticos (GRASP e GRASP reativo), iterações e tempo são médias sobre as 30 execuções. O menor gap de cada instância é destacado em negrito.

Table 9 – Resultados por instância: comparação dos cinco algoritmos. Custo = distância média; Gap em % ao melhor conhecido; Iter. e Tempo são médias (30 execuções para os estocásticos). O menor gap de cada instância está em negrito.

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
C101	I1	10,0	922,0	11,45	0	0,00
	VND	10,0	827,3	0,00	0	0,01
	GRASP	10,0	827,3	0,00	801	7,85
	GRASP-R	10,0	827,3	0,00	801	15,05
	Tabu	10,0	827,3	0,00	806	8,74
C102	I1	10,0	1039,7	25,67	0	0,00
	VND	10,0	827,3	0,00	0	0,02
	GRASP	10,0	827,3	0,00	802	21,76
	GRASP-R	10,0	827,3	0,00	801	29,08
	Tabu	10,0	827,3	0,00	816	4,90
C103	I1	11,0	1221,7	47,85	0	0,00
	VND	10,0	881,0	6,62	0	0,03
	GRASP	10,0	826,3	0,00	808	27,54
	GRASP-R	10,0	826,3	0,00	811	34,92
	Tabu	10,0	826,3	0,00	1027	6,00
C104	I1	10,0	1148,2	39,53	0	0,00
	VND	10,0	876,7	6,54	0	0,02
	GRASP	10,0	822,9	0,00	847	25,84
	GRASP-R	10,0	822,9	0,00	857	32,92
	Tabu	10,0	822,9	0,00	1662	9,66
C105	I1	10,0	878,9	6,24	0	0,00
	VND	10,0	827,3	0,00	0	0,01
	GRASP	10,0	827,3	0,00	801	8,39
	GRASP-R	10,0	827,3	0,00	801	18,01
	Tabu	10,0	827,3	0,00	806	8,78
C106	I1	11,0	951,2	14,98	0	0,00
	VND	10,0	827,3	0,00	0	0,01
	GRASP	10,0	827,3	0,00	801	11,82
	GRASP-R	10,0	827,3	0,00	801	20,39
	Tabu	10,0	827,3	0,00	812	4,14
C107	I1	10,0	902,4	9,08	0	0,00
	VND	10,0	827,3	0,00	0	0,01
	GRASP	10,0	827,3	0,00	801	9,59
	GRASP-R	10,0	827,3	0,00	801	20,04
	Tabu	10,0	827,3	0,00	806	8,10
C108	I1	10,0	975,2	17,88	0	0,00

continua na próxima página

continuação da Tabela 9

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
	VND	10,0	827,3	0,00	0	0,01
	GRASP	10,0	827,3	0,00	802	14,54
	GRASP-R	10,0	827,3	0,00	802	22,44
	Tabu	10,0	827,3	0,00	819	4,37
C109	I1	11,0	933,1	12,79	0	0,00
	VND	10,0	847,5	2,44	0	0,01
	GRASP	10,0	827,3	0,00	804	18,53
	GRASP-R	10,0	827,3	0,00	803	23,74
	Tabu	10,0	827,3	0,00	821	4,86
C201	I1	3,0	609,1	3,40	0	0,00
	VND	3,0	589,1	0,00	0	0,01
	GRASP	3,0	589,1	0,00	801	7,98
	GRASP-R	3,0	589,1	0,00	801	10,90
	Tabu	3,0	589,1	0,00	801	13,28
C202	I1	4,0	793,0	34,61	0	0,00
	VND	3,0	617,9	4,89	0	0,03
	GRASP	3,0	589,1	0,00	802	30,67
	GRASP-R	3,0	589,1	0,00	802	36,43
	Tabu	3,0	617,9	4,89	815	7,27
C203	I1	4,0	931,4	58,21	0	0,00
	VND	4,0	635,3	7,92	0	0,05
	GRASP	3,0	592,9	0,71	996	52,72
	GRASP-R	3,0	589,0	0,05	1158	72,19
	Tabu	3,0	588,7	0,00	929	7,92
C204	I1	4,0	1138,4	93,57	0	0,00
	VND	4,0	689,7	17,28	0	0,08
	GRASP	3,0	596,9	1,49	1328	89,50
	GRASP-R	3,0	596,7	1,47	1503	108,84
	Tabu	4,0	620,5	5,51	1220	9,56
C205	I1	4,0	667,6	13,85	0	0,00
	VND	3,0	606,8	3,48	0	0,01
	GRASP	3,0	586,4	0,00	803	12,72
	GRASP-R	3,0	586,4	0,00	803	16,43
	Tabu	3,0	586,4	0,00	812	7,46
C206	I1	3,0	660,6	12,73	0	0,00
	VND	3,0	586,0	0,00	0	0,01
	GRASP	3,0	586,0	0,00	801	18,14
	GRASP-R	3,0	586,0	0,00	801	20,75

continua na próxima página

continuação da Tabela 9

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
	Tabu	3,0	586,0	0,00	810	6,77
C207	I1	3,0	747,1	27,54	0	0,00
	VND	3,0	585,8	0,00	0	0,02
	GRASP	3,0	585,8	0,00	801	17,85
	GRASP-R	3,0	585,8	0,00	801	20,44
	Tabu	3,0	585,8	0,00	814	7,19
C208	I1	3,0	717,6	22,50	0	0,00
	VND	3,0	632,3	7,94	0	0,03
	GRASP	3,0	585,8	0,00	801	21,48
	GRASP-R	3,0	585,8	0,00	801	23,39
	Tabu	3,0	585,8	0,00	821	7,63
R101	I1	21,0	1867,1	14,01	0	0,00
	VND	21,0	1674,5	2,25	0	0,02
	GRASP	20,0	1641,3	0,22	1322	23,13
	GRASP-R	20,0	1641,7	0,25	1472	28,52
	Tabu	20,0	1644,3	0,40	828	3,55
R102	I1	19,0	1711,0	16,66	0	0,00
	VND	19,0	1493,0	1,80	0	0,03
	GRASP	18,2	1471,3	0,32	1302	43,48
	GRASP-R	18,0	1467,4	0,05	1379	49,02
	Tabu	19,0	1491,0	1,66	837	3,92
R103	I1	16,0	1550,0	28,24	0	0,00
	VND	16,0	1272,0	5,24	0	0,04
	GRASP	14,3	1221,1	1,03	1382	44,25
	GRASP-R	14,3	1223,1	1,19	1425	48,88
	Tabu	15,0	1240,4	2,62	1803	8,46
R104	I1	12,0	1267,5	30,47	0	0,00
	VND	12,0	1035,8	6,62	0	0,04
	GRASP	11,1	997,5	2,68	1442	42,97
	GRASP-R	11,1	998,7	2,80	1468	50,06
	Tabu	12,0	1022,6	5,26	887	4,92
R105	I1	15,0	1593,4	17,57	0	0,00
	VND	15,0	1414,4	4,36	0	0,02
	GRASP	15,3	1372,5	1,27	1282	26,85
	GRASP-R	15,4	1371,1	1,16	1330	31,50
	Tabu	15,0	1380,6	1,87	844	4,12
R106	I1	14,0	1446,6	17,17	0	0,00
	VND	14,0	1293,2	4,75	0	0,03

continua na próxima página

continuação da Tabela 9

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
	GRASP	13,1	1250,2	1,26	1498	41,74
	GRASP-R	13,1	1252,7	1,46	1481	45,82
	Tabu	14,0	1274,5	3,23	1026	5,38
R107	I1	12,0	1354,1	27,19	0	0,00
	VND	12,0	1159,1	8,88	0	0,03
	GRASP	11,6	1092,7	2,64	1424	38,80
	GRASP-R	11,7	1094,5	2,80	1472	46,48
	Tabu	12,0	1103,3	3,63	1044	5,66
R108	I1	11,0	1226,0	31,53	0	0,00
	VND	11,0	1042,6	11,86	0	0,04
	GRASP	10,7	960,7	3,07	1398	41,55
	GRASP-R	10,7	961,6	3,17	1412	48,00
	Tabu	11,0	979,0	5,03	1366	7,12
R109	I1	14,0	1457,8	27,11	0	0,00
	VND	14,0	1266,0	10,38	0	0,02
	GRASP	12,9	1168,5	1,88	1366	32,25
	GRASP-R	13,2	1170,2	2,03	1455	39,15
	Tabu	14,0	1229,8	7,23	970	5,08
R110	I1	12,0	1339,0	25,38	0	0,00
	VND	12,0	1193,4	11,74	0	0,01
	GRASP	12,0	1106,4	3,59	1557	39,82
	GRASP-R	12,1	1106,8	3,63	1458	42,92
	Tabu	12,0	1122,4	5,09	1105	5,82
R111	I1	12,0	1276,6	21,73	0	0,00
	VND	12,0	1190,9	13,56	0	0,01
	GRASP	12,0	1071,0	2,12	1313	36,39
	GRASP-R	11,9	1075,1	2,52	1381	44,47
	Tabu	12,0	1066,1	1,66	895	4,71
R112	I1	11,0	1188,1	25,25	0	0,00
	VND	11,0	1072,7	13,08	0	0,02
	GRASP	10,4	979,9	3,30	1361	32,24
	GRASP-R	10,7	983,3	3,65	1574	44,50
	Tabu	11,0	978,2	3,12	1934	10,32
R201	I1	5,0	1805,3	57,92	0	0,00
	VND	5,0	1277,3	11,73	0	0,05
	GRASP	5,1	1196,4	4,65	1400	64,54
	GRASP-R	5,2	1196,0	4,62	1451	69,66
	Tabu	5,0	1216,9	6,45	1371	9,65

continua na próxima página

continuação da Tabela 9

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
R202	I1	4,0	1585,0	53,94	0	0,00
	VND	4,0	1173,8	14,01	0	0,08
	GRASP	5,0	1046,3	1,63	1489	99,99
	GRASP-R	5,1	1049,2	1,90	1348	94,36
	Tabu	4,0	1116,1	8,40	849	6,96
R203	I1	4,0	1534,3	76,19	0	0,00
	VND	4,0	967,4	11,09	0	0,09
	GRASP	4,0	903,6	3,77	1499	134,72
	GRASP-R	4,2	899,2	3,26	1527	141,44
	Tabu	4,0	942,7	8,26	954	7,58
R204	I1	4,0	1155,2	57,97	0	0,00
	VND	4,0	828,9	13,35	0	0,07
	GRASP	3,2	751,9	2,82	1592	142,45
	GRASP-R	3,6	749,3	2,46	1331	122,64
	Tabu	4,0	758,0	3,65	1018	8,27
R205	I1	4,0	1403,3	47,75	0	0,00
	VND	4,0	1117,5	17,66	0	0,05
	GRASP	4,0	982,6	3,45	1386	71,47
	GRASP-R	4,0	980,7	3,25	1398	76,06
	Tabu	4,0	1028,4	8,28	1393	10,80
R206	I1	3,0	1303,5	48,82	0	0,00
	VND	3,0	1034,6	18,12	0	0,06
	GRASP	4,0	903,7	3,17	1430	95,45
	GRASP-R	4,0	901,2	2,89	1521	106,37
	Tabu	3,0	934,0	6,63	1719	16,20
R207	I1	3,0	1169,9	47,34	0	0,00
	VND	3,0	873,5	10,01	0	0,08
	GRASP	3,0	826,8	4,13	1340	115,28
	GRASP-R	3,3	822,6	3,60	1324	118,61
	Tabu	3,0	856,4	7,86	1070	9,43
R208	I1	3,0	974,0	38,94	0	0,00
	VND	3,0	792,7	13,08	0	0,07
	GRASP	3,0	709,1	1,16	1457	123,61
	GRASP-R	3,0	709,5	1,21	1358	117,87
	Tabu	3,0	729,7	4,09	1900	17,70
R209	I1	4,0	1322,5	54,72	0	0,00
	VND	4,0	954,6	11,68	0	0,07
	GRASP	4,0	880,0	2,95	1525	88,31

continua na próxima página

continuação da Tabela 9

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
	GRASP-R	4,0	881,9	3,17	1360	84,69
	Tabu	4,0	913,9	6,91	1563	12,00
R210	I1	4,0	1404,0	55,91	0	0,00
	VND	4,0	973,1	8,06	0	0,07
	GRASP	4,0	932,7	3,57	1458	98,89
	GRASP-R	4,2	931,0	3,39	1356	96,10
	Tabu	4,0	922,1	2,40	1068	8,29
R211	I1	3,0	1013,4	35,72	0	0,00
	VND	3,0	965,4	29,29	0	0,03
	GRASP	3,0	785,1	5,15	1535	86,04
	GRASP-R	3,1	785,4	5,19	1421	84,37
	Tabu	3,0	812,2	8,77	1384	11,72
RC101	I1	17,0	1920,4	18,56	0	0,00
	VND	17,0	1706,6	5,36	0	0,02
	GRASP	16,4	1642,8	1,42	1368	30,15
	GRASP-R	16,7	1646,9	1,67	1437	33,66
	Tabu	17,0	1676,2	3,48	841	4,02
RC102	I1	15,0	1813,3	24,42	0	0,00
	VND	15,0	1533,1	5,19	0	0,03
	GRASP	14,7	1477,5	1,38	1354	39,36
	GRASP-R	14,9	1478,8	1,47	1366	43,22
	Tabu	15,0	1492,6	2,42	1279	6,44
RC103	I1	12,0	1544,5	22,77	0	0,00
	VND	12,0	1334,9	6,11	0	0,02
	GRASP	11,9	1285,8	2,21	1279	40,49
	GRASP-R	11,7	1286,5	2,26	1479	51,55
	Tabu	12,0	1335,3	6,14	839	4,06
RC104	I1	12,0	1380,6	21,93	0	0,00
	VND	12,0	1201,5	6,11	0	0,03
	GRASP	10,3	1155,2	2,02	1494	40,76
	GRASP-R	10,6	1158,5	2,31	1570	49,75
	Tabu	12,0	1197,0	5,71	955	5,12
RC105	I1	16,0	1838,0	21,42	0	0,00
	VND	15,0	1568,1	3,59	0	0,03
	GRASP	15,4	1538,7	1,65	1405	42,80
	GRASP-R	15,3	1540,1	1,74	1450	46,11
	Tabu	15,0	1558,8	2,98	839	4,14
	I1	14,0	1726,5	25,77	0	0,00

continua na próxima página

RC106

continuação da Tabela 9

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
	VND	14,0	1542,6	12,38	0	0,02
	GRASP	13,4	1407,9	2,56	1421	33,31
	GRASP-R	13,4	1409,3	2,66	1409	37,53
	Tabu	13,0	1397,7	1,82	1664	8,77
RC107	I1	13,0	1587,4	31,43	0	0,00
	VND	13,0	1296,0	7,30	0	0,03
	GRASP	12,1	1238,9	2,57	1308	33,90
	GRASP-R	12,3	1246,9	3,24	1410	41,89
	Tabu	13,0	1264,4	4,69	954	5,02
RC108	I1	11,0	1368,2	22,80	0	0,00
	VND	11,0	1183,8	6,25	0	0,03
	GRASP	11,1	1129,0	1,33	1573	39,09
	GRASP-R	11,0	1134,6	1,83	1337	39,16
	Tabu	11,0	1148,9	3,11	923	4,96
RC201	I1	5,0	2025,4	60,52	0	0,00
	VND	5,0	1494,7	18,46	0	0,04
	GRASP	5,3	1315,0	4,21	1438	57,93
	GRASP-R	5,7	1314,5	4,18	1458	61,58
	Tabu	5,0	1350,1	7,00	2240	15,68
RC202	I1	4,0	1783,8	63,31	0	0,00
	VND	4,0	1288,8	17,99	0	0,05
	GRASP	5,0	1116,6	2,22	1237	75,20
	GRASP-R	5,0	1117,9	2,34	1321	83,39
	Tabu	4,0	1244,4	13,93	873	6,69
RC203	I1	4,0	1528,8	65,51	0	0,00
	VND	4,0	1006,8	9,00	0	0,09
	GRASP	4,1	961,8	4,13	1577	114,48
	GRASP-R	4,7	955,4	3,44	1199	90,09
	Tabu	4,0	992,7	7,47	1261	9,71
RC204	I1	4,0	1254,4	60,10	0	0,00
	VND	4,0	837,1	6,84	0	0,06
	GRASP	4,0	792,7	1,17	1267	99,96
	GRASP-R	4,0	791,1	0,97	1332	109,68
	Tabu	4,0	818,2	4,43	1117	8,75
RC205	I1	5,0	2179,4	88,86	0	0,00
	VND	5,0	1380,9	19,66	0	0,06
	GRASP	6,0	1208,8	4,75	1378	72,26
	GRASP-R	6,2	1202,0	4,16	1553	85,44

continua na próxima página

continuação da Tabela 9

Instância	Alg.	Veíc.	Custo	Gap (%)	Iter.	Tempo (s)
	Tabu	5,0	1282,2	11,11	1080	7,52
RC206	I1	4,0	1743,1	65,84	0	0,00
	VND	4,0	1092,8	3,97	0	0,06
	GRASP	4,0	1080,6	2,81	1218	60,28
	GRASP-R	4,1	1079,1	2,66	1263	66,62
	Tabu	4,0	1078,6	2,62	974	7,43
RC207	I1	4,0	1565,7	62,60	0	0,00
	VND	4,0	1104,5	14,71	0	0,08
	GRASP	4,7	1011,2	5,01	1293	82,63
	GRASP-R	5,0	1003,5	4,21	1515	99,03
	Tabu	4,0	1042,1	8,22	871	7,19
RC208	I1	3,0	1155,9	48,94	0	0,00
	VND	3,0	926,6	19,39	0	0,04
	GRASP	3,4	847,8	9,24	1363	64,71
	GRASP-R	4,0	816,3	5,18	1374	70,75
	Tabu	3,0	877,5	13,06	967	9,12

B Invariância das conclusões ao orçamento de parada

O valor de K é um orçamento declarado (Seção 3.13), e não um parâmetro derivado dos dados. Cabe portanto verificar se alguma conclusão do estudo depende dele. A Tabela 10 repete, para cada orçamento medido, o ordenamento dos três métodos iterativos e os testes par a par de Wilcoxon sobre as instâncias de treino. Numa faixa de $64 \times$ (K de 50 a 3200) nem o ordenamento nem o resultado dos testes se alteram.

Table 10 – Invariância das conclusões ao orçamento, nas instâncias de treino. Em toda a faixa medida — uma variação de $64 \times$ — o ordenamento dos métodos e o resultado dos testes par a par (Wilcoxon pareado) não se alteram. Nenhuma conclusão do estudo depende do valor de K adotado. Semente única: o *não significativo* entre GRASP e Reativo deve ser lido como ausência de evidência, não como equivalência estabelecida.

K	ordenamento	p (GRASP $\times$ Reativo)	p (GRASP $\times$ Tabu)
50	Reativo < GRASP < Tabu	0.2675	0.0029
100	Reativo < GRASP < Tabu	0.1531	0.0015
200	Reativo < GRASP < Tabu	0.9544	0.0003
400	Reativo < GRASP < Tabu	0.9181	0.0006
800	Reativo < GRASP < Tabu	0.7060	0.0009
1600	Reativo < GRASP < Tabu	0.1591	0.0012
3200	Reativo < GRASP < Tabu	0.7481	0.0005

Referências

- ALMEIDA, L. G. de; BORIN, J. F. Plataforma inteligente e sustentável para coleta de resíduos baseada em IoT e LPWAN. In: WORKSHOP DE COMPUTAÇÃO URBANA (COURB), 2021. *Anais [...]*. SBC, 2021. p. 154–167.
- BARTH, L.; SCHWEIGER, L.; BENEDECH, R.; EHRAT, M. From data to value in smart waste management. *Decision Analytics Journal*, v. 9, p. 100347, 2023.
- BENAVOLI, A.; CORANI, G.; MANGILI, F. Should we really use post-hoc tests based on mean-ranks? *Journal of Machine Learning Research*, v. 17, n. 5, p. 1–10, 2016.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- DIMACS. *12th DIMACS Implementation Challenge — Vehicle Routing: VRPTW track (Competition Rules)*. Rutgers University, 2021–2022. Disponível em: <http://dimacs.rutgers.edu/programs/challenge/vrp/vrptw/>.
- CVRPLIB. *Capacitated Vehicle Routing Problem Library — instâncias Solomon do VRPTW e melhores soluções conhecidas*. PUC-Rio. Disponível em: <https://galgos.inf.puc-rio.br/cvrplib/>.
- FEO, T. A.; RESENDE, M. G. C. Greedy randomized adaptive search procedures. *Journal of Global Optimization*, v. 6, n. 2, p. 109–133, 1995.
- GARCÍA, S.; HERRERA, F. An extension on “Statistical comparisons of classifiers over multiple data sets” for all pairwise comparisons. *Journal of Machine Learning Research*, v. 9, p. 2677–2694, 2008.
- GLOVER, F. Tabu search: part I. *ORSA Journal on Computing*, v. 1, n. 3, p. 190–206, 1989.
- GLOVER, F. Tabu search: part II. *ORSA Journal on Computing*, v. 2, n. 1, p. 4–32, 1990.
- HANSEN, P.; MLADENović, N. Variable neighborhood search: principles and applications. *European Journal of Operational Research*, v. 130, n. 3, p. 449–467, 2001.
- LÓPEZ-IBÁÑEZ, M. et al. The irace package: iterated racing for automatic algorithm configuration. *Operations Research Perspectives*, v. 3, p. 43–58, 2016.
- LOZANO, Á. et al. Smart waste collection system with low consumption LoRaWAN nodes and route optimization. *Sensors*, v. 18, n. 5, p. 1465, 2018.
- PARDINI, K. et al. A smart waste management solution geared towards citizens. *Sen-*

sors, v. 20, n. 8, p. 2380, 2020.

OR, I. *Traveling salesman-type combinatorial problems and their relation to the logistics of regional blood banking*. Tese (Doutorado) — Northwestern University, Evanston, 1976.

POTVIN, J.-Y.; ROUSSEAU, J.-M. An exchange heuristic for routing problems with time windows. *Journal of the Operational Research Society*, v. 46, n. 12, p. 1433–1446, 1995.

TAILLARD, É.; BADEAU, P.; GENDREAU, M.; GUERTIN, F.; POTVIN, J.-Y. A tabu search heuristic for the vehicle routing problem with soft time windows. *Transportation Science*, v. 31, n. 2, p. 170–186, 1997.

PRAIS, M.; RIBEIRO, C. C. Reactive GRASP. *INFORMS Journal on Computing*, v. 12, n. 3, p. 164–176, 2000.

RAMSON, S. R. J. et al. A LoRaWAN IoT-enabled trash bin level monitoring system. *IEEE Transactions on Industrial Informatics*, v. 18, n. 2, p. 786–795, 2021.

RESENDE, M. G. C.; RIBEIRO, C. C. Greedy randomized adaptive search procedures. In: *Handbook of Metaheuristics*. Springer, 2003. p. 219–249.

SOLOMON, M. M. Algorithms for the vehicle routing and scheduling problems with time window constraints. *Operations Research*, v. 35, n. 2, p. 254–265, 1987.

TOTH, P.; VIGO, D. (ed.). *The Vehicle Routing Problem*. SIAM, 2002.