

Otimização Dinâmica de Rotas para Coleta de Resíduos Sólidos: Adaptação do Algoritmo de Solomon com Integração IoT

Edital:	Edital PiiC 2025/2026
Grande Área do Conhecimento (CNPq):	Ciências Exatas e da Terra
Área do Conhecimento (CNPq):	Ciência da Computação
Título do Projeto:	Pesquisa Operacional e Inovação em Logística Regional
Título do Subprojeto:	Otimização Dinâmica de Rotas para Coleta de Resíduos Sólidos: Adaptação do Algoritmo de Solomon com Integração IoT
Professor Orientador:	Maria Claudia Silva Boeres
Estudante:	Emilly Lopes Das Neves

Resumo

A coleta de resíduos sólidos urbanos baseada em rotas e frequências fixas responde mal ao enchimento real dos recipientes, gerando deslocamentos desnecessários e transbordos. Este subprojeto comparou, sob condições controladas e reproduzíveis, cinco heurísticas clássicas para o Problema de Roteamento de Veículos com Janelas de Tempo (VRPTW): a inserção II de Solomon, a Descida em Vizinhaça Variável (VND), o GRASP nas formas fixa e reativa e a Busca Tabu. Todos os métodos compartilham o mesmo núcleo de código, de modo que as diferenças observadas decorram exclusivamente da estratégia de busca. Foram avaliadas as 56 instâncias de Solomon com 100 clientes, com calibração de parâmetros pelo pacote irace sob divisão treino/teste, parada por iterações sem melhora e comparação estatística por Friedman, Nemenyi e Wilcoxon. As variantes de GRASP obtiveram os menores desvios de distância, abaixo de 2% do melhor conhecido, seguidas da Busca Tabu, do VND e da II; nenhuma das 3.528 execuções produziu solução inviável. Por fim, um gêmeo digital aplicou os algoritmos calibrados à coleta seletiva de Vitória/ES, com malha viária real e comunicação LoRaWAN simulada: a coleta dinâmica guiada por sensores reduziu o número de coletas em 46%, com nível de serviço governado pelo limiar de acionamento.

Palavras-chave: Problema de Roteamento de Veículos com Janelas de Tempo. Meta-heurísticas. GRASP. Busca Tabu. Gêmeo digital. Coleta de resíduos.

1 Introdução

A gestão de resíduos sólidos urbanos impõe desafios operacionais, econômicos e ambientais aos municípios. Sistemas convencionais de coleta, baseados em rotas fixas e frequências predeterminadas, geram deslocamentos desnecessários e respondem mal a situações de enchimento crítico dos recipientes (Pardini et al., 2020; Lozano et al., 2018). A literatura aponta que integrar monitoramento em tempo real e otimização de rotas pode tornar a coleta mais eficiente (Lozano et al., 2018; Barth et al., 2023), inclusive em experiências nacionais com redes LPWAN (Almeida; Borin, 2021).

Este Subprojeto de Iniciação Científica combina sensoriamento IoT via LoRaWAN (Ramson et al., 2022) com heurísticas baseadas no algoritmo de inserção de Solomon (1987) para o VRPTW, além de um gêmeo digital (*Digital Twin*) para simulação e visualização. A pergunta de pesquisa é: *de que modo a comparação criteriosa de heurísticas clássicas para o VRPTW pode fundamentar um planejamento de coleta mais responsivo e eficiente, preservando a factibilidade temporal das rotas?* O subprojeto vincula-se ao Projeto de Pesquisa “Pesquisa Operacional e Inovação em Logística Regional”, no qual constitui a frente de otimização de rotas e de simulação orientada a sensores.

A contribuição é metodológica e experimental, organizada em três camadas: (i) um *benchmark* estático sobre as

instâncias clássicas de Solomon, que estabelece a base de comparação e calibra os algoritmos; (ii) uma análise estatística do desempenho relativo dos cinco métodos; e (iii) uma aplicação dinâmica (gêmeo digital) que transfere os algoritmos calibrados a um cenário de coleta de resíduos com dados reais de Vitória/ES, reaproveitando os mesmos operadores e parâmetros validados no *benchmark*.

2 Objetivos

O objetivo geral do subprojeto foi comparar experimentalmente, de forma controlada e reprodutível, cinco heurísticas clássicas para o VRPTW construídas sobre o algoritmo de Solomon, e avaliar a transferência dos métodos calibrados a um cenário dinâmico de coleta de resíduos guiado por sensores IoT. Os objetivos específicos foram:

- implementar as cinco heurísticas sobre um núcleo de código único, com viabilidade das soluções garantida por construção e conferida por um verificador independente;
- selecionar, por ablação estatística, o conjunto de operadores de vizinhança compartilhado pelos métodos de melhoria;
- calibrar os parâmetros de cada meta-heurística com o pacote *irace*, sob divisão treino/teste e com critério de aceitação declarado antes da calibração;
- comparar os métodos nas 56 instâncias de Solomon com testes estatísticos pareados (Friedman, Nemenyi e Wilcoxon com correção de Holm);
- construir um gêmeo digital da coleta seletiva de Vitória/ES, com localizações reais, malha viária real e camada de comunicação LoRaWAN simulada, e confrontar o regime de coleta dinâmico com o estático.

Esses objetivos respondem a duas necessidades. Sem um terreno experimental comum, comparações entre heurísticas confundem a estratégia de busca com diferenças de implementação; e, sem medir o compromisso entre esforço de coleta e nível de serviço, não há base para decidir se a coleta guiada por sensores compensa frente à coleta de frequência fixa.

3 Embasamento Teórico

O problema. No VRPTW, formalizado por Solomon (1987) e consolidado por Toth e Vigo (2002), uma frota homogênea de veículos de capacidade Q parte de um depósito e deve visitar cada cliente exatamente uma vez, respeitando a demanda q_i , a janela de tempo $[e_i, \ell_i]$ e o tempo de serviço s_i de cada cliente i , além do horizonte $[e_0, \ell_0]$ do depósito. A cada arco (i, j) associam-se uma distância d_{ij} e um tempo de viagem t_{ij} . Uma *rota* é uma sequência $r = \langle 0, c_1, \dots, c_m, 0 \rangle$; definindo a chegada $a_{c_k} = b_{c_{k-1}} + s_{c_{k-1}} + t_{c_{k-1}, c_k}$ (com $a_{c_1} = t_{0, c_1}$) e o início de serviço $b_{c_k} = \max(a_{c_k}, e_{c_k})$, a rota é viável se satisfaz a condição (1):

$$b_{c_k} \leq \ell_{c_k} \quad \forall k, \quad \sum_k q_{c_k} \leq Q, \quad b_{c_m} + s_{c_m} + t_{c_m, 0} \leq \ell_0. \quad (1)$$

Uma *solução* S é um conjunto de rotas $\mathcal{R}(S)$ que cobre cada cliente exatamente uma vez, e suas grandezas de interesse, definidas na equação (2), são a distância total $D(S)$ e o número de veículos $K(S)$:

$$D(S) = \sum_{r \in \mathcal{R}(S)} \sum_{(i,j) \in r} d_{ij}, \quad K(S) = |\mathcal{R}(S)|. \quad (2)$$

Convenção de distância e objetivo. Adota-se a convenção do 12º Desafio de Implementação DIMACS para o VRPTW (DIMACS, 2022): a distância de cada arco é a euclidiana truncada a uma casa decimal, $d_{ij} = \lfloor 10 e_{ij} \rfloor / 10$, e o tempo de viagem é igual à distância. O objetivo otimizado é $\min D(S)$ sobre as soluções viáveis, com $K(S)$ reportado como medida secundária — diferentemente da hierarquia lexicográfica clássica de Solomon (1987), que minimiza primeiro o número de veículos. A convenção foi escolhida por ser o padrão internacional moderno e por

ser verificável: ela reproduz exatamente os custos das soluções de referência de mínima distância do repositório CVRPLIB (2026), adotadas neste trabalho como base de comparação; o repositório SINTEF (2026) publica as referências da hierarquia de mínima frota, incomparáveis com as primeiras sem reconversão.

As heurísticas comparadas. A heurística de inserção I1 (Solomon, 1987) constrói soluções viáveis de forma gulosa e sequencial e é a partida comum dos demais métodos, que exploram vizinhanças clássicas do VRPTW (Toth; Vigo, 2002) por estratégias distintas: a Descida em Vizinhança Variável (VND) percorre as vizinhanças em ordem fixa de complexidade, reiniciando da primeira a cada melhoria (Hansen; Mladenović, 2001); o GRASP repete ciclos de construção gulosa-aleatorizada seguida de busca local, retendo a melhor solução (Feo; Resende, 1995), e sua variante reativa aprende, durante a execução, qual grau de aleatorização funciona melhor (Prais; Ribeiro, 2000); a Busca Tabu segue trajetória única, aceitando piores controladas e proibindo temporariamente a reversão de movimentos recentes (Glover, 1989).

Coleta inteligente e gêmeo digital. Sensores de nível em lixeiras, conectados por redes de longo alcance e baixo consumo como o LoRaWAN (Adelantado et al., 2017; Ramson et al., 2022), permitem acionar a coleta pelo enchimento real. Um *gêmeo digital* é uma representação virtual de um sistema físico, mantida atualizada por leituras de sensores, na qual decisões de operação podem ser ensaiadas e medidas antes de ir às ruas (Barth et al., 2023). Para o realismo viário, distâncias e tempos de direção podem ser obtidos da malha do OpenStreetMap pelo serviço de roteamento OSRM (Luxen; Vetter, 2011).

Calibração e comparação estatística. A configuração automática de parâmetros usa o pacote *irace* (López-Ibáñez et al., 2016); seu mecanismo é a *corrida* (*racing*): a cada rodada, um teste estatístico elimina as configurações candidatas que já se mostram inferiores, concentrando o orçamento de avaliações nas sobreviventes. Para comparar algoritmos sobre múltiplas instâncias, segue-se o protocolo de Demšar (2006): teste de Friedman sobre os postos (*ranks*) por instância, seguido do pós-teste de Nemenyi; comparações par a par são adicionalmente examinadas por Wilcoxon pareado com correção de Holm (García; Herrera, 2008).

4 Metodologia

Trata-se de pesquisa aplicada, de objetivo explicativo-comparativo, abordagem quantitativa e procedimento experimental: experimentos computacionais controlados sobre o *benchmark* público de Solomon, complementados por um estudo de simulação. O material experimental são as 56 instâncias clássicas de Solomon (1987) com 100 clientes, nas famílias C (clientes agrupados), R (aleatórios) e RC (mistos), cada uma nos tipos 1 (horizonte de planejamento curto) e 2 (horizonte longo). As atividades executadas pela estudante — implementação, calibração, experimentação e análise — compõem a parcela que coube ao subprojeto dentro do Projeto de Pesquisa ao qual está vinculado.

Núcleo compartilhado e fluxo de execução. Os cinco algoritmos foram implementados em C++20 (compilados com g++ -O2, sem dependências externas) sobre um núcleo único: leitor das instâncias de Solomon, matriz de distâncias truncadas (único ponto onde distâncias são calculadas, e que admite matrizes explícitas de distância e tempo no gêmeo digital), estrutura de rota com caches dos instantes de chegada, início e partida, avaliador de custo, conjunto de vizinhanças, gerador pseudoaleatório com semente registrada, critério de parada e verificador independente. Compartilhar o núcleo é o que torna a comparação pertinente: a estratégia de busca passa a ser a única origem possível das diferenças. Cada execução lê a instância, constrói a solução inicial pela I1 (ou pela construção aleatorizada, no GRASP), refina-a pelo método em avaliação e grava rotas, métricas e traços de convergência; um *pipeline* em Python executa as trincas (algoritmo, instância, semente) em paralelo, agrega os resultados e gera tabelas e figuras — todo o experimento é reproduzível por um único comando. A semente de cada execução combina o número da execução com um *hash* determinístico do nome da instância, descorrelacionando os fluxos aleatórios

entre instâncias e tornando cada execução reproduzível em qualquer plataforma; uma suíte de 34 testes unitários cobre o núcleo e a fidelidade dos algoritmos à literatura.

Invariantes de viabilidade. Toda solução produzida satisfaz a condição (1) e a cobertura dos clientes, por três mecanismos redundantes: (i) cada operador avalia o movimento candidato simulando a rota afetada, e movimentos inviáveis são descartados antes da comparação de custo; (ii) inserções são testadas em tempo $O(1)$ pelo critério *Push Forward* de Solomon (1987), que mantém, para cada cliente, a folga máxima de adiamento que não viola nenhuma janela subsequente; e (iii) um verificador independente reavalia toda solução final do zero — apenas a partir da sequência de clientes, da instância e da matriz de distâncias —, funcionando como portão de correteude: um defeito nos caches incrementais da busca não teria como se autovalidar. O pipeline trata qualquer violação como erro fatal, interrompendo o estudo em vez de registrá-la e seguir.

Construção (heurística II de Solomon). A construção segue a heurística sequencial II de Solomon (1987) na variante baseada em distância. Cada rota nasce de uma *semente* (o cliente não roteado mais distante do depósito) e cresce por inserções guiadas por dois critérios, definidos na equação (3): c_1 mede o custo de inserir o cliente u entre os vizinhos (i, j) , e c_2 mede a economia de aproveitá-lo na rota corrente em vez de servi-lo depois em viagem dedicada,

$$\begin{aligned} c_{11}(i, u, j) &= d_{iu} + d_{uj} - \mu d_{ij}, & c_{12}(i, u, j) &= b_{ju} - b_j, \\ c_1(i, u, j) &= \alpha_1 c_{11}(i, u, j) + \alpha_2 c_{12}(i, u, j), & c_2(u) &= \lambda d_{0u} - c_1^{\min}(u), \end{aligned} \quad (3)$$

em que c_{11} é o acréscimo de distância, c_{12} é o deslocamento temporal que u provoca no sucessor j (com b_j e b_{ju} os inícios de serviço antes e depois da inserção) e $c_1^{\min}(u)$ é o custo da melhor posição *viável* de u na rota corrente. Usa-se a configuração canônica $\mu = 1$, $\lambda = 2$, $\alpha_1 = 1$ e $\alpha_2 = 0$, fixa para todos os métodos: com $\alpha_2 = 0$, o critério reduz-se ao acréscimo de distância, coerente com o objetivo adotado. O Algoritmo 1 formaliza o procedimento.

Algoritmo 1 II-SOLOMON — construção por inserção sequencial

Entrada: conjunto de clientes C ; parâmetros $\mu, \lambda, \alpha_1, \alpha_2$

Saída: solução viável S cobrindo todos os clientes

```

1:  $S \leftarrow \emptyset$ ;  $U \leftarrow C$ 
2: enquanto  $U \neq \emptyset$  faça
3:    $u^* \leftarrow \arg \max_{u \in U} d_{0u}$ ;  $r \leftarrow \langle u^* \rangle$ ;  $U \leftarrow U \setminus \{u^*\}$ 
4:   repita
5:      $best \leftarrow \text{NULO}$ ;  $c_2^* \leftarrow -\infty$ 
6:     para todo  $u \in U$  com inserção viável em  $r$  faça
7:       se  $c_2(u) > c_2^*$  então
8:          $c_2^* \leftarrow c_2(u)$ ;  $best \leftarrow (u, \arg \min_{(i,j)} c_1(i, u, j))$ 
9:       fim se
10:    fim para
11:    se  $best \neq \text{NULO}$  então
12:       $\text{insere}(best, r)$ ;  $U \leftarrow U \setminus \{u_{best}\}$ 
13:    fim se
14:  até  $best = \text{NULO}$ 
15:   $S \leftarrow S \cup \{r\}$ 
16: fim enquanto
17: retorne  $S$ 

```

Na linha 1, a solução começa vazia e o conjunto U de clientes não roteados recebe todos os clientes. Na linha 3, a rota corrente nasce da semente, escolha que ancora a rota em uma região periférica e tende a reduzir o número

de veículos. O laço interno (linhas 5–12) faz a rota crescer: a varredura da linha 6 percorre apenas os clientes com inserção viável — cada posição testada em $O(1)$ pela folga *Push Forward* — e a linha 8 retém o cliente de maior c_2 junto com sua melhor posição, inserido na linha 12. A rota fecha (linha 15) quando nenhuma inserção viável resta, e uma nova é aberta. A cobertura é garantida estruturalmente (o laço externo só termina com $U = \emptyset$, e cada iteração roteia ao menos a semente); a viabilidade, pela restrição da varredura. Restam rotas densas, mas sem reotimização entre si — a lacuna que a busca local explora.

Conjunto de vizinhanças. Os métodos de melhoria compartilham um *kit* de seis operadores clássicos, listado na ordem de exploração:

- **2-opt** (intrarota): inverte um subtrecho de uma rota;
- **Swap** (intrarota e entre rotas): troca dois clientes de posição;
- **2-opt*** (entre rotas): troca as caudas de duas rotas (Potvin; Rousseau, 1995);
- **Relocate** (intrarota e entre rotas): remove um cliente e o reinsere em outra posição;
- **Or-opt** (intrarota e entre rotas): move uma cadeia de 2–3 clientes, eventualmente invertida (Or, 1976);
- **Cross-exchange** (entre rotas): troca subtrechos de até 3 clientes entre duas rotas (Taillard et al., 1997).

Os seis operadores cobrem os oito movimentos avaliados no relatório parcial: Relocate, Swap e Or-opt implementam as variantes intrarota e entre rotas em varredura única, e o “2-opt entre rotas” do parcial corresponde ao 2-opt*. Conforme ali previsto, o conjunto foi submetido a seleção por ablação nas instâncias de treino (Seção 5): como a remoção de qualquer operador piora o *gap* médio — a distância percentual entre a solução obtida e a melhor solução conhecida da instância, métrica definida formalmente na Seção 5 —, o subconjunto selecionado é o próprio kit completo. A ordem de exploração é a de custo *medido* de uma varredura completa, conferida por teste automatizado — no pior caso, as seis varreduras têm a mesma ordem assintótica $O(n^3)$, e o que as distingue são as constantes multiplicativas, que a notação assintótica esconde.

Descida em Vizinhança Variável (VND). O VND (Hansen; Mladenović, 2001) percorre as vizinhanças em ordem fixa, da varredura mais barata à mais cara, com estratégia de *melhor melhora*: a cada passo aplica o movimento viável de maior redução de $D(S)$ e reinicia da primeira vizinhança; quando nenhuma vizinhança melhora, para em um ótimo local em relação a todas elas. O Algoritmo 2 formaliza o método; a função `melhor_movimento` devolve o movimento viável de maior redução de distância em N_ℓ , ou NULO se nenhum reduz.

Algoritmo 2 VND — Descida em Vizinhança Variável

Entrada: solução viável S ; vizinhanças ordenadas $N_1, \dots, N_p$

Saída: ótimo local S em relação a todas as vizinhanças

```

1:  $\ell \leftarrow 1$ 
2: enquanto  $\ell \leq p$  faça
3:    $m \leftarrow \text{melhor\_movimento}(N_\ell, S)$ 
4:   se  $m \neq \text{NULO}$  então
5:      $S \leftarrow \text{aplica}(m, S)$ ;  $\ell \leftarrow 1$ 
6:   senão
7:      $\ell \leftarrow \ell + 1$ 
8:   fim se
9: fim enquanto
10: retorne  $S$ 
```

Na linha 3, a vizinhança ativa N_ℓ é varrida por completo; a escolha do melhor movimento (e não do primeiro) torna o resultado determinístico dado o ponto de partida. Havendo ganho, a linha 5 aplica o movimento e *reinicia* da primeira vizinhança — é o que caracteriza o VND e faz os operadores baratos (2-opt, Swap) absorverem a maior

parte dos movimentos, reduzindo o trabalho dos carros. Sem ganho, a linha 7 avança para a vizinhança seguinte, e o laço encerra quando nenhuma das p vizinhanças melhora S . A trajetória de custos é monotônica decrescente, mas o método permanece preso ao primeiro ótimo local — limitação da qual partem as meta-heurísticas.

GRASP. O GRASP (Feo; Resende, 1995) repete o ciclo construção aleatorizada → busca local e guarda a melhor solução encontrada. A construção reusa a I1, substituindo a escolha gulosa por um sorteio uniforme dentro da Lista Restrita de Candidatos (RCL) definida na equação (4): sendo $c^{\max}$ e $c^{\min}$ o maior e o menor valor de c_2 entre os candidatos,

$$\text{RCL} = \{ u : c_2(u) \geq c^{\max} - \alpha (c^{\max} - c^{\min}) \}, \quad \alpha \in [0, 1], \quad (4)$$

de modo que $\alpha = 0$ recupera a construção gulosa e $\alpha = 1$, a totalmente aleatória. A busca local é o próprio VND. O Algoritmo 3 resume o método, com K o número máximo de iterações consecutivas sem melhora.

Algoritmo 3 GRASP

Entrada: instância; parâmetro α ; orçamento K

Saída: melhor solução S^*

```

1:  $S^* \leftarrow \text{I1-SOLOMON}$ ;  $k \leftarrow 0$ 
2: enquanto  $k < K$  faça
3:    $S \leftarrow \text{CONSTRUÇÃO-ALEATORIZADA}(\alpha)$ 
4:    $S \leftarrow \text{VND}(S)$ 
5:   se  $D(S) < D(S^*)$  então
6:      $S^* \leftarrow S$ ;  $k \leftarrow 0$ 
7:   senão
8:      $k \leftarrow k + 1$ 
9:   fim se
10: fim enquanto
11: retorne  $S^*$ 
```

Na linha 1, o incumbente é inicializado com a solução da I1 pura — a mesma partida entregue ao VND e à Busca Tabu —, o que garante que o GRASP nunca termine pior que a I1 e põe todos os métodos partindo do mesmo ponto. Cada iteração gera uma solução nova com aleatorização controlada por α (linha 3) e a conduz a um ótimo local (linha 4); as linhas 6–8 retêm o melhor já visto e controlam a estagnação. Com $\alpha = 0$ o método degenera na construção da I1, propriedade conferida por teste automatizado nas 56 instâncias. O acréscimo do GRASP é a diversificação estruturada: reconstruindo as rotas do zero a cada iteração, rompe a dependência da semente única da I1, e o resultado é a melhor entre centenas de descidas independentes (Resende; Ribeiro, 2003).

GRASP reativo. A variante reativa (Prais; Ribeiro, 2000) difere do GRASP apenas em como α é escolhido: mantém-se uma grade discreta $\{\alpha_1, \dots, \alpha_g\}$ (aqui 0,05, 0,10, $\dots$, 0,50, $g = 10$) com probabilidades de seleção p_i , inicialmente uniformes. Nas primeiras g iterações cada valor é experimentado uma vez (aquecimento); depois, α é sorteado segundo p e, a cada $block$ iterações, as probabilidades são atualizadas pela equação (5),

$$q_i = \left(\frac{Z^*}{\bar{Z}_i} \right)^\delta, \quad p_i = \frac{q_i}{\sum_j q_j}, \quad (5)$$

em que Z^* é o custo do incumbente, $\bar{Z}_i$ é o custo médio das soluções obtidas com α_i e o expoente δ regula a agressividade do aprendizado. Na implementação, o tamanho de bloco é derivado como $block = block_frac \cdot K$, para que o número de reponderações independa do orçamento; como $block \geq 16 > g$ em toda a faixa calibrada, a primeira reponderação só ocorre com todos os α_i já experimentados. O efeito prático é ajustar automaticamente o

equilíbrio guloso-aleatório ao perfil de cada instância.

Busca Tabu. Adota-se a forma clássica (Glover, 1989): a cada iteração, move-se para o melhor vizinho *admissível* do kit de vizinhanças, mesmo que piore a solução corrente — é assim que a busca escapa de ótimos locais —, e o incumbente S^* retém o menor custo visitado. Um movimento é *tabu* se algum dos seus clientes-atributo (o primeiro cliente de cada segmento movido) foi movido nas últimas *tenure* iterações, salvo se produzir um novo melhor global (aspiração por objetivo). Adota-se também a aspiração por omissão (Glover; Laguna, 1997): se todos os movimentos estiverem tabu, revoga-se o grupo de proibições com expiração mais próxima e refaz-se a varredura, em vez de encerrar a busca. O Algoritmo 4 formaliza o método; *melhor_admissível* devolve o melhor movimento viável não tabu (ou tabu com aspiração), ou NULO.

Algoritmo 4 BUSCA-TABU — forma clássica

Entrada: solução inicial S (da I1); *tenure*; orçamento K

Saída: melhor solução S^*

```

1:  $S^* \leftarrow S$ ;  $k \leftarrow 0$ 
2: enquanto  $k < K$  faça
3:    $m \leftarrow \text{melhor\_admissível}(N, S)$ 
4:   enquanto  $m = \text{NULO}$  e algum cliente está tabu faça
5:     expira o grupo tabu de prazo mais próximo;  $m \leftarrow \text{melhor\_admissível}(N, S)$ 
6:   fim enquanto
7:   se  $m = \text{NULO}$  então
8:     retorne  $S^*$ 
9:   fim se
10:   $S \leftarrow \text{aplica}(m, S)$ ; marca os clientes-atributo de  $m$  como tabu por tenure iterações
11:  se  $D(S) < D(S^*)$  então
12:     $S^* \leftarrow S$ ;  $k \leftarrow 0$ 
13:  senão
14:     $k \leftarrow k + 1$ 
15:  fim se
16: fim enquanto
17: retorne  $S^*$ 

```

Na linha 3, todo o kit é varrido em busca do melhor movimento admissível; diferentemente do VND, a linha 10 pode aplicar uma piora controlada, e a marcação tabu impede a busca de reverter movimentos recentes e ciclar. O *tenure* regula o compromisso central do método: valores pequenos intensificam a busca na região atual; valores grandes forçam a exploração de regiões novas. O laço das linhas 4–5 implementa a aspiração por omissão, sem consumir iteração; o retorno da linha 8 só ocorre se não existir movimento viável algum, tabu ou não. A Tabu refina a estrutura herdada da I1 em trajetória única e contínua; o GRASP, ao contrário, explora múltiplas estruturas independentes.

Parametrização, critério de parada e calibração. Cada parâmetro pertence a uma de três categorias. Os *fixos* definem o terreno comum da comparação e por isso não podem ser ajustados por método: os coeficientes canônicos da I1, o kit e a ordem das vizinhanças e a convenção de distância. Os *calibrados* são os de qualidade intrínsecos a cada meta-heurística, ajustados pelo *irace* (López-Ibáñez et al., 2016) sobre 28 instâncias de treino (metade das 56, estratificadas por família e tipo), com o gap ao melhor conhecido como função-objetivo: a largura da RCL $\alpha \in (0; 0,5)$ no GRASP; o expoente $\delta \in (0,5; 3,0)$ e a fração *block_frac* $\in (0,02; 0,40)$ no reativo; e *tenure* $\in (5; 80)$ na Tabu. Os *declarados* são orçamentos computacionais, para os quais não existe valor ótimo a descobrir: como

mais iterações sem melhora nunca pioram o resultado, calibrar o critério de parada K pelo gap o levaria sempre ao teto do intervalo, confundindo orçamento com qualidade — declará-lo é a prática consolidada na literatura de GRASP, tanto na forma básica (Feo; Resende, 1995) quanto na reativa (Prais; Ribeiro, 2000). Adotou-se $K = 800$ iterações sem melhora, uniforme entre os métodos, com teto de segurança de 600 s; na faixa medida de $K = 50$ a $K = 3200$ (variação de 64×), nem o ordenamento dos métodos nem o resultado dos testes par a par se alteram, de modo que nenhuma conclusão depende dessa escolha. A parada por iterações, e não por tempo, favorece a reprodutibilidade; como uma iteração não custa o mesmo em cada método, tempo e iterações são reportados junto às demais métricas. Por fim, o protocolo de aceitação da calibração foi declarado *antes* da corrida do *irace*: o valor calibrado só substitui o clássico da literatura se o superar nas 28 instâncias de teste com Wilcoxon pareado a 5%; caso contrário, adota-se o clássico.

Protocolo estatístico. Cada método estocástico executa 30 vezes por instância com sementes independentes; os determinísticos (I1, VND, Tabu), uma vez. A comparação global usa o teste de Friedman sobre os postos por instância, com correção para empates (frequentes na família C), seguido do pós-teste de Nemenyi (Demšar, 2006): dois métodos diferem se seus postos médios distam mais que a diferença crítica da equação (6),

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6N}}, \quad (6)$$

com k algoritmos, N instâncias e q_α o valor crítico do *range* estudentizado — para $k = 5$, $\alpha = 0,05$ e $N = 56$, $CD = 0,815$. Cada par de interesse é adicionalmente examinado por Wilcoxon pareado sobre os gaps por instância, com correção de Holm (García; Herrera, 2008); conclusões afirmadas no texto exigem concordância entre as duas leituras. Os experimentos foram conduzidos em uma única máquina (Intel Core Ultra 9 285K, Ubuntu 24.04, g++ 13.3).

Gêmeo digital da coleta seletiva de Vitória/ES. A terceira camada aplica os algoritmos calibrados a um cenário de coleta com localizações reais: os 38 pontos de entrega voluntária (PEVs) de coleta seletiva de Vitória/ES, obtidos dos dados abertos do município, com depósito na associação de triagem AMARIV. Cada PEV é uma lixeira monitorada — o “cliente” do VRPTW. Trata-se de uma *prova de conceito*: as localizações são reais, mas o enchimento é sintético, calibrado pela literatura de resíduos urbanos (Lozano et al., 2018; Barth et al., 2023), pois a coleta de séries reais exigiria meses de monitoramento. O nível de enchimento $f \in [0, 1]$ de cada lixeira evolui por um processo de Poisson não homogêneo discretizado em ciclos (8 ciclos/dia, cerca de 3 h cada), com intensidade entre $\lambda_{\text{off}} = 0,8$ e $\lambda_{\text{pico}} = 4,0$ em dois picos diários, propensão heterogênea por lixeira ($p_i \sim \mathcal{U}(0,5; 1,5)$) e incremento $\Delta f = \text{chegadas}/12$. Uma lixeira *transborda* se f atinge 1 antes de ser coletada — o indicador de falha de serviço, contado por *episódio*: cada enchimento completo conta um único transbordo, e a lixeira só volta a poder transbordar depois de coletada. A demanda de coleta deriva do enchimento por demanda = $\text{round}(9f) + 1$, entre 1 e 10: é medida de prioridade e volume a recolher, não peso físico.

A cada ciclo, as lixeiras acima do limiar de acionamento τ (padrão 0,7) tornam-se uma instância VRPTW com *janela de tempo dinâmica*: com criticidade $\text{crit} = \max(0, (f - \tau)/(1 - \tau))$, o prazo de coleta é dado pela equação (7),

$$due = H(1 - \kappa \cdot \text{crit}), \quad (7)$$

em que H é o horizonte de planejamento e κ (padrão 0,6) é o coeficiente de urgência — quanto mais cheia a lixeira, mais cedo o prazo, o que antecipa as lixeiras críticas dentro das rotas via folga *Push Forward*. O solver é o mesmo binário do *benchmark*, com os parâmetros aprovados no estudo estático e o mesmo critério de parada; o plano de cada ciclo é *atômico* (as rotas são executadas por inteiro dentro do próprio ciclo, e as lixeiras roteadas são esvaziadas antes do ciclo seguinte), de modo que o horizonte e as janelas dinâmicas atuam como priorização dentro do plano,

não como calendário entre ciclos. Os parâmetros herdados do *benchmark* são defensáveis porque a calibração ajusta apenas a estratégia de busca (largura da RCL, memória de proibição, cadência do aprendizado reativo), nada que dependa da geometria da instância; a ausência de recalibração no cenário viário — que exigiria treinar sobre o próprio simulador — fica registrada como limitação.

Entre os sensores e o planejador há uma camada de comunicação que simula os efeitos relevantes de uma rede LoRaWAN classe A com *uplinks* não confirmados (Adelantado et al., 2017; Ramson et al., 2022): perda de pacote (entrega com probabilidade *pdr*, padrão 0,98, sem retransmissão), ciclo de trabalho (cada sensor transmite a cada *duty* ciclos, com fases sorteadas) e idade da leitura (entre transmissões, ou após uma perda, o planejador segue com a última leitura recebida). O planejamento decide, portanto, sobre a *visão de rádio* do sistema, enquanto o transbordo é contado no estado físico — um transbordo ocorrido enquanto a lixeira estava invisível ao rádio é atribuível à comunicação, não ao roteamento. Para o realismo viário, as matrizes de distância (metros) e tempo de direção (segundos) entre depósito e PEVs vêm da malha do OpenStreetMap via OSRM (Luxen; Vetter, 2011), com horizonte $H = 6$ h e serviço de 120 s; o fator de circuito médio (distância rodoviária sobre linha reta) foi de 1,53, chegando a 6,9 em pares separados por água.

A validação compara dois regimes de operação: o *dinâmico* (coleta sob demanda das lixeiras acima do limiar a cada ciclo) e o *estático* (coleta de todas as lixeiras a cada 3 ciclos, independentemente do enchimento). A comparação é pareada sobre 30 realizações independentes de enchimento — em cada semente, os dois regimes veem exatamente a mesma sequência de chegadas — com teste de Wilcoxon pareado; para os empates, frequentes em indicadores inteiros, usa-se o tratamento *zsplit* (empates divididos igualmente entre os postos positivos e negativos, em vez de descartados). Como limiar, capacidade e coeficiente de urgência são escolhas de modelagem, reporta-se também uma análise de sensibilidade variando um parâmetro por vez sobre uma mesma realização de enchimento.

5 Resultados e Discussão

O desempenho é medido pelo *gap* percentual de distância ao melhor conhecido, definido na equação (8),

$$\text{gap}(\%) = 100 \cdot \frac{d - d^{\text{bk}}}{d^{\text{bk}}}, \quad (8)$$

em que d é a distância obtida e d^{bk} a da solução de referência de mínima distância (CVRPLIB, 2026), recomputada sob a mesma convenção truncada; o *gap* normaliza as escalas entre instâncias. Antes de qualquer comparação, a implementação foi validada reproduzindo o custo declarado das 56 soluções de referência (diferença absoluta $\leq 0,05$ em todas) — um portão: nenhum resultado foi considerado antes de ele passar. Em todas as 3.528 execuções do estudo, o verificador independente não acusou nenhuma solução inviável e nenhum *gap* negativo ocorreu, o que confirma empiricamente o invariante de viabilidade da Seção 4.

Ablação do conjunto de vizinhanças. A Tabela 1 quantifica a contribuição de cada operador removendo um por vez do kit completo, sempre sobre as mesmas 28 instâncias de treino e a mesma solução inicial. A remoção de qualquer operador piora o *gap* médio, o que sustenta o kit completo como resultado da seleção. O Relocate é o operador dominante (+3,15 pontos percentuais ao ser removido, piora em 23 das 28 instâncias, $p = 0,0015$), seguido do 2-opt* (+1,42 pp), mais valioso nas famílias de geografia dispersa. Apenas Relocate e Or-opt atingem significância — e isso não autoriza remover os demais: o Cross-exchange, por exemplo, altera o resultado em somente 4 das 28 instâncias, e com tão poucas observações não nulas o teste de Wilcoxon não alcança $p < 0,05$ nem no melhor cenário; a ausência de significância aqui é falta de poder do teste, não indício de que o operador seja dispensável.

Tabela 1 – Ablação *leave-one-out* do conjunto de vizinhanças (VND, 28 instâncias de treino): efeito de remover cada operador do kit completo, com o placar por instância e o p de Wilcoxon pareado sob correção de Holm

Configuração	Gap médio (%)	Δ (pp)	piora/melhora/empata	p (Holm)	signif.
Kit completo (6 operadores)	8,25	—	—	—	—
sem Relocate	11,40	+3,15	23/4/1	0,0015	sim
sem 2-opt*	9,67	+1,42	16/6/6	0,1745	não
sem 2-opt intra	9,25	+1,00	8/8/12	0,7476	não
sem Swap	9,23	+0,98	13/8/7	0,5349	não
sem Or-opt	9,01	+0,76	12/1/15	0,0216	sim
sem Cross-exchange	8,75	+0,50	4/0/24	0,5349	não

Fonte: Produção da própria autora.

Efeito da calibração. A Tabela 2 confronta, nas 28 instâncias de teste, os parâmetros calibrados com os clássicos da literatura, sob o protocolo de aceitação pré-declarado. O resultado difere por método. Na Busca Tabu, calibrar rendeu +1,26 pp ($p = 0,043$): o *tenure* calibrado (49) fica bem acima do clássico (15), indicando que, sob um kit de seis vizinhanças — cuja vizinhança conjunta é grande —, proibições mais longas são necessárias para forçar a exploração. No GRASP, o calibrado ($\alpha = 0,22$) não superou o clássico ($\alpha = 0,30$; $p = 0,63$), e o protocolo determina adotar o clássico no estudo final; esse resultado negativo é informativo: o GRASP é insensível a α na faixa 0,2–0,3 nestas instâncias. No reativo, o ganho é positivo e limítrofe (+0,03 pp, $p = 0,0496$), lido como “não pior que o clássico, com indício fraco de vantagem”; os valores calibrados mantidos foram $\delta = 1,85$ e *block_frac* = 0,0275. O superajuste é pequeno: a diferença de gap entre treino e teste fica entre 0,10 e 0,24 pp nos três métodos.

Tabela 2 – Parâmetros clássicos da literatura ($\alpha=0,30$; $\delta=1,0$, *block_frac*= 0,1; *tenure*= 15) contra os calibrados pelo *irace*, nas 28 instâncias de teste, nunca vistas pela calibração, com 30 sementes por método estocástico e o mesmo $K = 800$. Ganho positivo = calibrado melhor; p do teste de Wilcoxon pareado

Cenário	Gap clássico (%)	Gap calibrado (%)	Ganho (pp)	melhor/pior/empate	p
GRASP	2,01	2,03	-0,02	9/11/8	0,6316
GRASP reativo	2,03	2,00	+0,03	14/6/8	0,0496
Busca Tabu	5,30	4,04	+1,26	13/6/9	0,0431

Fonte: Produção da própria autora.

Comparação de desempenho. Com os parâmetros aprovados e $K = 800$ uniforme, executou-se o estudo completo. A Tabela 3 resume o desempenho global: o gap médio agrega, sobre as 56 instâncias, a média das 30 execuções de cada método estocástico, e o gap melhor toma a melhor execução por instância — a distância entre os dois mede o quanto a aleatoriedade ajuda. A cadeia construção → busca local → meta-heurística rende, em média, a queda de 35,97% (I1 pura) para 8,43% (VND) e daí para menos de 2% (GRASP e reativo): cada camada contribui, e a maior contribuição individual é a da busca local. As colunas de esforço mostram o GRASP gastando, em média, cerca de 57 s por execução contra 7,6 s da Busca Tabu — razão que varia de 0,6× a 17× por instância, de modo que “a Tabu responde mais rápido” é caracterização média, não garantia.

Tabela 3 – Desempenho global nas 56 instâncias (gap de distância ao melhor conhecido; 30 execuções por instância para GRASP e GRASP reativo, uma para os determinísticos). *Iterações* e *tempo* são médias por execução; a iteração tem custo diferente em cada método, e os dois números tornam esse esforço explícito

Algoritmo	Gap médio (%)	Gap melhor (%)	Veículos	Iterações	Tempo (s)
Solomon I1	35,97	—	8,46	—	0,000
VND	8,43	—	8,36	—	0,037
GRASP	1,96	0,99	8,30	1249	57,2
GRASP reativo	1,88	1,02	8,29	1249	56,6
Busca Tabu	3,95	—	8,29	1088	7,6

Fonte: Produção da própria autora.

A Tabela 4 detalha o padrão por família: na família C, de clientes agrupados, todos os métodos de melhoria chegam perto do ótimo — a estrutura de agrupamentos deixa pouco espaço para reotimização —, enquanto R e RC, de geografia dispersa, separam os métodos com clareza.


Tabela 4 – Gap médio de distância por família (%). As famílias diferem na geografia dos clientes (C agrupada, R aleatória, RC mista), e a dificuldade relativa dos métodos muda com ela

Algoritmo	C (agrupada)	R (aleatória)	RC (mista)
Solomon I1	26,58	37,28	44,05
VND	3,36	10,98	10,14
GRASP	0,14	2,54	3,05
GRASP reativo	0,09	2,59	2,77
Busca Tabu	0,61	4,89	6,14

Fonte: Produção da própria autora.

O resultado primário usa o conjunto de teste, que a calibração nunca viu. O teste de Friedman rejeita a igualdade entre os cinco métodos ($\chi_F^2 = 94,15$, $p = 1,7 \times 10^{-19}$), com postos médios GRASP 1,77, reativo 1,84, Tabu 2,63, VND 3,77 e I1 5,00; nas 56 instâncias o quadro é o mesmo ($\chi_F^2 = 185,36$, $p = 5,3 \times 10^{-39}$). As comparações par a par por Wilcoxon com Holm dão o quadro final: todos os pares diferem significativamente, *exceto* GRASP $\times$ reativo ($p = 0,95$); em particular, as duas variantes de GRASP superam a Busca Tabu ($p_{\text{Holm}} = 6,9 \times 10^{-4}$, com o GRASP melhor em 18 das 28 instâncias de teste e pior em 3). A hierarquia empírica é, portanto, GRASP $\approx$ reativo $>$ Tabu $>$ VND $>$ I1, sintetizada no diagrama de diferença crítica da Figura 1; a diferença de postos GRASP–Tabu nas 56 instâncias (0,83) excede a diferença crítica com e sem a I1 no conjunto comparado ($CD = 0,815$ e $0,627$). Como análise complementar da dimensão tempo $\times$ qualidade, os métodos foram reexecutados sob orçamento de tempo fixo ($T = 20$ s), avaliados pela integral primal PI do desafio (DIMACS, 2022) — métrica dependente da máquina, reportada apenas como complemento. A integral primal média ordena os métodos assim: GRASP ($PI = 3,08$), GRASP reativo ($PI = 3,10$), Busca Tabu ($PI = 4,25$), VND ($PI = 8,61$) (menor é melhor). O VND converge quase instantaneamente, mas estaciona no ótimo local, o que penaliza sua integral; sob tempo igual, a leitura é a mesma da comparação primária, com distâncias encurtadas entre os métodos.

Figura 1 – Diagrama de diferença crítica (Friedman/Nemenyi, 56 instâncias): cada método na posição do seu posto médio (esquerda = melhor); uma barra une métodos estatisticamente indistinguíveis a 5%



Fonte: Produção da própria autora.

Quanto ao número de veículos, a média dos métodos ($\approx 8,3$) situa-se entre o das referências de mínima distância e o das de mínima frota (SINTEF, 2026) — assinatura esperada da minimização de distância, não um defeito: as referências de mínima distância usam mais veículos e distância menor ou igual à das soluções de mínima frota em todas as 56 instâncias (em 37, estritamente menor).

Gêmeo digital. A Tabela 5 apresenta a comparação pareada entre os regimes dinâmico e estático sobre 30 realizações de enchimento no cenário dos 38 PEVs. O quadro é de *compromisso*, não de dominância: o regime dinâmico realiza pouco mais da metade das coletas do estático (123,9 contra 228,0, em média — redução de 46% do esforço), que é a economia operacional que motiva a coleta guiada por sensores; em contrapartida, no limiar padrão $\tau = 0,7$, incorre em *mais* transbordos (27,0 contra 19,1 episódios, $p < 0,001$) e distância comparável, ligeiramente maior ($p = 0,0016$): esperar a lixeira encher 70% para agendá-la deixa pouca margem antes do transbordo.

Tabela 5 – Gêmeo digital (Vitória/ES, 16 ciclos, canal LoRaWAN com $pdr = 0,98$): coleta dinâmica guiada pelos sensores contra coleta estática de frequência fixa (a cada 3 ciclos), sobre 30 realizações independentes de enchimento — os dois regimes veem a *mesma* realização em cada semente (comparação pareada). Células: média $\pm$ IC95%. Transbordos contados por *episódio* (a lixeira atinge a capacidade antes da coleta; uma contagem por enchimento). Última linha: p do teste de Wilcoxon pareado sobre as 30 sementes


Regime	Distância	Coletas	Transbordos	Ciclos com rota
Dinâmico (sob demanda)	3751,0 $\pm$ 72,7	123,9 $\pm$ 2,5	27,0 $\pm$ 2,0	15,0 $\pm$ 0,1
Estático (a cada 3 ciclos)	3663,6 $\pm$ 36,9	228,0 $\pm$ 0,0	19,1 $\pm$ 2,1	6,0 $\pm$ 0,0
p (Wilcoxon pareado)	0,0016	0,0000	0,0000	0,0000

Fonte: Produção da própria autora.

A análise de sensibilidade, variando um parâmetro por vez sobre uma mesma realização, delimita o papel de cada um: o limiar τ domina o compromisso serviço-custo (de 5 a 61 transbordos ao variar τ de 0,5 a 0,9; com $\tau = 0,5$, a realização analisada registra 5 transbordos e 167 coletas, ainda bem abaixo das 228 coletas do regime estático); a capacidade do veículo reduz fortemente a distância (de 6 527 a 3 049 ao variar de 15 a 40) sem afetar transbordos; e o coeficiente de urgência não altera os indicadores agregados desta configuração, pois, no horizonte folgado do cenário, as janelas dinâmicas raramente restringem a viabilidade — atuam só na priorização interna ao plano. O efeito do canal é mensurável: no mapa da instância R101, com 12 ciclos e o VND como roteador, degradar o canal perfeito para $pdr = 0,9$ com transmissão a cada 2 ciclos elevou os transbordos de 51 para 96 episódios, com defasagem média de 0,52 ciclo — além do roteamento, a própria qualidade da comunicação limita o serviço. Nas instâncias pequenas de cada ciclo (tipicamente 10–20 lixeiras ativas), os métodos de melhoria convergem a rotas de custo muito próximo: as distinções medidas no *benchmark* de 100 clientes manifestam-se em problemas maiores.

Por fim, a Figura 2 mostra as rotas sobre a malha viária real: rotear os 38 PEVs produziu 6 veículos, 83,7 km de percurso e 3,7 h de operação.

Figura 2 – Rotas do gêmeo digital sobre a malha viária real de Vitória/ES: cada cor é um caminhão, traçado pela geometria de direção real; a estrela é o depósito (AMARIV)



Fonte: Produção da própria autora, com malha viária do OpenStreetMap obtida via OSRM (Luxen; Vetter, 2011).

6 Conclusões

Este subprojeto construiu uma comparação controlada de cinco heurísticas clássicas para o VRPTW — núcleo de código compartilhado, viabilidade garantida por construção e conferida por verificador independente, calibração com portão de aceitação pré-declarado e comparação estatística pareada — e transferiu os métodos calibrados a um gêmeo digital da coleta seletiva de Vitória/ES. Quanto à pergunta de pesquisa: a comparação controlada estabeleceu, com significância estatística, a hierarquia entre as estratégias de busca — GRASP e sua variante reativa, indistinguíveis entre si, à frente da Busca Tabu, do VND e da I1 —, e a transferência ao cenário dinâmico mostrou que a coleta guiada por sensores preserva a factibilidade temporal das rotas e reduz o esforço de coleta em 46%, com o nível de serviço governado pelo limiar de acionamento: no limiar padrão, os transbordos superam os do regime fixo, e limiares mais baixos recuperam o serviço mantendo a economia de coletas.

As principais limitações delimitam o alcance das conclusões: o objetivo otimizado é apenas a distância (a hierarquia lexicográfica veículos → distância não foi avaliada como objetivo); a Busca Tabu foi mantida na forma mais simples, sem memória de longo prazo; no gêmeo digital, o enchimento é simulado e não medido, a camada LoRaWAN é representada e não validada energeticamente, os hiperparâmetros são herdados do *benchmark* euclidiano sem recalibração no cenário viário, e a análise de sensibilidade usa uma única realização de enchimento (a comparação entre regimes usa 30). A principal dificuldade metodológica foi evitar que escolhas de configuração enviesassem a comparação — respondida com o desenho de parâmetros fixos, calibrados e declarados e com a verificação de que as conclusões independem do orçamento de parada.

As contribuições são: no âmbito acadêmico, um protocolo reprodutível de comparação de meta-heurísticas (partida comum, ablação, calibração com portão, testes pareados) e a evidência de que, sob objetivo de distância, o GRASP domina a Busca Tabu clássica nas instâncias de Solomon; no âmbito profissional e social, a quantificação

do compromisso entre esforço de coleta e transbordos na coleta guiada por sensores, com o limiar de acionamento apontado como a alavanca operacional decisiva. Como continuidade, sugerem-se: validação com dados reais de enchimento em Vitória (piloto com sensores); avaliação sob o critério lexicográfico; variantes mais ricas (Tabu com memória de longo prazo, híbridos com religação de caminhos); planos que atravessam ciclos no gêmeo digital, com replanejamento de veículos em rota; e quantificação de benefícios econômicos e ambientais.

Agradecimentos

À Universidade Federal do Espírito Santo e ao Programa Institucional de Iniciação Científica (Piic/UFES), pelo apoio institucional a esta pesquisa; e à orientadora, pela condução do trabalho.

Referências Bibliográficas

- ADELANTADO, F.; VILAJOSANA, X.; TUSET-PEIRO, P.; MARTINEZ, B.; MELIÀ-SEGUÍ, J.; WATTEYNE, T. Understanding the limits of LoRaWAN. **IEEE Communications Magazine**, [s. l.], v. 55, n. 9, p. 34-40, 2017.
- ALMEIDA, L. G. de; BORIN, J. F. Plataforma inteligente e sustentável para coleta de resíduos baseada em IoT e LPWAN. In: **WORKSHOP DE COMPUTAÇÃO URBANA (COURB)**, 5., 2021. **Anais [...]**. Porto Alegre: SBC, 2021. p. 154-167.
- BARTH, L.; SCHWEIGER, L.; BENEDECH, R.; EHRAT, M. From data to value in smart waste management: optimizing solid waste collection with a digital twin-based decision support system. **Decision Analytics Journal**, [s. l.], v. 9, p. 100347, 2023.
- CVRPLIB. **Capacitated Vehicle Routing Problem Library**: instâncias Solomon do VRPTW e melhores soluções conhecidas. Rio de Janeiro: PUC-Rio, 2026. Disponível em: <https://galgos.inf.puc-rio.br/cvrplib/>. Acesso em: 12 ago. 2026.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, [s. l.], v. 7, p. 1-30, 2006.
- DIMACS. **12th DIMACS Implementation Challenge — Vehicle Routing**: VRPTW track (competition rules). New Brunswick: Rutgers University, 2022. Disponível em: <http://dimacs.rutgers.edu/programs/challenge/vrp/vrptw/>. Acesso em: 12 ago. 2026.
- FEO, T. A.; RESENDE, M. G. C. Greedy randomized adaptive search procedures. **Journal of Global Optimization**, [s. l.], v. 6, n. 2, p. 109-133, 1995.
- GARCÍA, S.; HERRERA, F. An extension on “Statistical comparisons of classifiers over multiple data sets” for all pairwise comparisons. **Journal of Machine Learning Research**, [s. l.], v. 9, p. 2677-2694, 2008.
- GLOVER, F. Tabu search: part I. **ORSA Journal on Computing**, [s. l.], v. 1, n. 3, p. 190-206, 1989.
- GLOVER, F.; LAGUNA, M. **Tabu Search**. Boston: Kluwer Academic Publishers, 1997.
- HANSEN, P.; MLADENOVIC, N. Variable neighborhood search: principles and applications. **European Journal of Operational Research**, [s. l.], v. 130, n. 3, p. 449-467, 2001.
- LÓPEZ-IBÁÑEZ, M.; DUBOIS-LACOSTE, J.; CÁCERES, L. P.; BIRATTARI, M.; STÜTZLE, T. The irace package: iterated racing for automatic algorithm configuration. **Operations Research Perspectives**, [s. l.], v. 3, p. 43-58, 2016.
- LOZANO, Á.; CARIDAD, J.; DE PAZ, J. F.; VILLARRUBIA GONZÁLEZ, G.; BAJO, J. Smart waste

collection system with low consumption LoRaWAN nodes and route optimization. **Sensors**, [s. l.], v. 18, n. 5, p. 1465, 2018.

LUXEN, D.; VETTER, C. Real-time routing with OpenStreetMap data. *In*: ACM SIGSPATIAL INTERNATIONAL CONFERENCE ON ADVANCES IN GEOGRAPHIC INFORMATION SYSTEMS, 19., 2011, Chicago. **Proceedings** [...]. New York: ACM, 2011. p. 513-516.

OR, I. **Traveling salesman-type combinatorial problems and their relation to the logistics of regional blood banking**. 1976. Tese (Doutorado) — Northwestern University, Evanston, 1976.

PARDINI, K.; RODRIGUES, J. J. P. C.; DIALLO, O.; DAS, A. K.; ALBUQUERQUE, V. H. C. de; KOZLOV, S. A. A smart waste management solution geared towards citizens. **Sensors**, [s. l.], v. 20, n. 8, p. 2380, 2020.

POTVIN, J.-Y.; ROUSSEAU, J.-M. An exchange heuristic for routeing problems with time windows. **Journal of the Operational Research Society**, [s. l.], v. 46, n. 12, p. 1433-1446, 1995.

PRAIS, M.; RIBEIRO, C. C. Reactive GRASP: an application to a matrix decomposition problem in TDMA traffic assignment. **INFORMS Journal on Computing**, [s. l.], v. 12, n. 3, p. 164-176, 2000.

RAMSON, S. R. J.; VISHNU, S.; KIRUBARAJ, A. A.; ANAGNOSTOPOULOS, T.; ABU-MAHFOUZ, A. M. A LoRaWAN IoT-enabled trash bin level monitoring system. **IEEE Transactions on Industrial Informatics**, [s. l.], v. 18, n. 2, p. 786-795, 2022.

RESENDE, M. G. C.; RIBEIRO, C. C. Greedy randomized adaptive search procedures. *In*: GLOVER, F.; KOCHENBERGER, G. A. (ed.). **Handbook of Metaheuristics**. Boston: Kluwer Academic Publishers, 2003. p. 219-249.

SINTEF. **Solomon benchmark — 100 customers**: best known solutions (minimum vehicles). Trondheim: SINTEF Transport Optimisation Portal, 2026. Disponível em: <https://www.sintef.no/projectweb/top/vrptw/100-customers/>. Acesso em: 12 ago. 2026.

SOLOMON, M. M. Algorithms for the vehicle routing and scheduling problems with time window constraints. **Operations Research**, [s. l.], v. 35, n. 2, p. 254-265, 1987.

TAILLARD, É.; BADEAU, P.; GENDREAU, M.; GUERTIN, F.; POTVIN, J.-Y. A tabu search heuristic for the vehicle routing problem with soft time windows. **Transportation Science**, [s. l.], v. 31, n. 2, p. 170-186, 1997.

TOTH, P.; VIGO, D. (ed.). **The Vehicle Routing Problem**. Philadelphia: SIAM, 2002.